

Warum die Arbeit ihren eigenen Zahlen so wenig traut

Band 1 hat erklärt, was untersucht wurde und was herauskam. Dieser Band geht dahinter: Wie die Daten überhaupt entstanden sind, warum aus 4.752 Zeilen nur rund 39 unabhängige Einheiten werden, was die Suche nach den richtigen Einstellungen in Wahrheit findet — und ob ein solches Modell seine Fehler gerecht verteilt.

Anschluss an: „Kann man ausrechnen, wo die Feuerwehr gebraucht wird?“ Fachbegriffe aus Band 1 werden hier vorausgesetzt; neue sind beim ersten Auftreten erklärt und im Glossar am Ende gesammelt.

Abbildungen: fortlaufend ab Nummer 13

Markierung: **ZUSATZ** kennzeichnet Angaben, die nicht in der Arbeit stehen

TEIL 6

Wie aus sieben Beständen eine Tabelle wird

Band 1 zeigte einen Trichter: sieben Quellen rein, eine Tabelle raus. Was in diesem Trichter passiert, ist ein großer Teil der Arbeit — und der Teil, in dem folgenreiche Entscheidungen fallen. Drei davon lohnen eine genauere Betrachtung.

Erstens: Die Zeitfalle

Ein Modell soll etwas vorhersagen. Das klingt selbstverständlich, hat aber eine harte Konsequenz: Es darf ausschließlich mit Informationen rechnen, die zum Zeitpunkt der Vorhersage *schon existierten*. Wer diese Regel verletzt, baut ein Modell, das hervorragende Werte erreicht und trotzdem nichts vorhersagt — es liest die Antwort ab. Der Fachbegriff dafür ist **Datenleckage**.


In dieser Arbeit gibt es vor allem zwei Stellen, an denen die Falle zuschnappen könnte. Die erste sind die Einsatzmeldungen selbst. Sie enthalten Felder, die erst *nach* dem Einsatz feststehen. Die Arbeit nennt zehn solche Felder, darunter die eingesetzten Löschfahrzeuge, die Alarmstufe und den Ankunftszeitpunkt; laut Projektcode sind es außerdem geschätzter Sachschaden, Löschkräfte, Rettungsdiensteinheiten, Antwortzeit, zivile Tote, zivile Verletzte und ob die Flammenausbreitung eingedämmt wurde **ZUSATZ**. Alle zehn hängen eng mit der Zielgröße zusammen. Ein Modell mit ihnen erreichte glänzende Werte — und wäre wertlos.

Die Arbeit sperrt sie nicht erst beim Modellieren, sondern schon *beim Bilden der beiden Analysedateien*. Was gar nicht erst in die Datei gelangt, kann später nicht versehentlich in ein Modell geraten. Beide Dateien bestehen nur aus fest aufgezählten Spalten, und für die Datei der Einsatzart wird zusätzlich automatisiert geprüft, dass keines der zehn Felder darin steht.

Zweitens: Der Publikationsversatz

Die zweite Falle ist subtiler und betrifft die Sozialdaten. Die amerikanische Statistikbehörde veröffentlicht Fünfjahresschätzungen: Der Jahrgang 2023 bündelt die Erhebungen von 2019 bis 2023 und erscheint erst *nach* deren Ablauf. Für einen Einsatz im Jahr 2023 war der Jahrgang 2023 also noch gar nicht verfügbar.

EIN EINSATZ IM JULI 2020 — WELCHER SOZIALDATEN-JAHRGANG IST ERLAUBT?



Die Regel lautet: ACS-Jahrgang höchstens Einsatzjahr minus eins. Der Versatz steht als benannte Konstante an einer einzigen Stelle im Code — nicht verstreut in der Rechnung, wo ihn niemand mehr fände.

Abbildung 13: Der Publikationsversatz der Sozialdaten. Die Zeitachse ist zur Veranschaulichung gewählt; die Regel selbst — Jahrgang höchstens Einsatzjahr minus eins — steht wörtlich so in der Arbeit.

ZUSATZ Laut Projektcode erscheint ein Jahrgang erst im Dezember des Folgejahres, der Jahrgang 2019 also im Dezember 2020. Die Regel schließt damit das Einsatzjahr selbst aus, aber nicht jeden Vorgriff: Im Juli 2020 war auch der verwendete Jahrgang 2019 noch nicht erschienen.

Diese Regel wird nicht auf die fertige Monatstabelle angewendet, sondern auf *jeden einzelnen Einsatz*. Die Arbeit begründet das so: Jeder Einsatz trägt seinen eigenen Zeitpunkt, und auf dieser Ebene lässt sich ihm genau der Stand zuordnen, der damals verfügbar war. Die Zwischentabelle hat deshalb 719.989 Zeilen und 50 Spalten — eine Zeile je Einsatz. Zwingend ist dieser Weg bei einer Regel, die nur auf das Jahr schaut, allerdings nicht: Auch jede Zeile der fertigen Monatstabelle kennt ihr Jahr, die Zuordnung ließe sich also auch dort vornehmen **ZUSATZ**.

Nach demselben Gedanken ist auch der Kriminalitätsindex gebaut. Er misst nicht die Kriminalität *dieses* Monats, sondern die der **zwölf Vormonate**. Eine im selben Monat gemessene Kriminalität würde die Einsätze dieses Monats erklären statt sie vorherzusagen.

Ganz ohne Vorgriff kommt die Arbeit allerdings nicht aus, und sie sagt das selbst: Die drei baulichen Merkmale gibt es nur als Stand von 2020. Für die ersten Jahre des Zeitraums verletzen sie damit die Verfügbarkeitsregel. Die Abweichung bleibt nach der Arbeit begrenzt, weil das Verzeichnis keine Angaben zu Einsätzen enthält.

Drittens: Zwei Karten, die nicht zueinander passen

Die Sozialdaten liegen für kleine statistische Bezirke vor, die Arbeit rechnet aber auf Stadtteilen. Es braucht also eine Übersetzungstabelle — einen **Crosswalk**. Der Haken: Die Behörde zieht diese Bezirksgrenzen periodisch neu. Die verwendete Übersetzungstabelle folgt den Grenzen von 2020, zwei der genutzten Jahrgänge aber noch denen von 2010.

Über die reine Kennung greift die Zuordnung in diesen beiden Jahrgängen deshalb nur für 79,7 % der Bezirke. Aufgefangen wird das über den vierstelligen Basiscode der Bezirksnummer: Wird ein Bezirk geteilt, dürfen die Teile ihn behalten und unterscheiden sich nur im Suffix. Damit steigt die Quote auf 99,2 bis 99,5 % je Jahrgang. Und die Aufbereitung bricht ab, sobald weniger als 95 % der Einwohner eines Jahrgangs zugeordnet sind.

WARUM DIESE SCHWELLE DA STEHT

Sie ist keine Sorgfaltsroutine, sondern die Lehre aus einem konkreten Fehler. Ein reiner Gleichheitsverbund verwarf 40 der 197 Bezirke zweier Jahrgänge — und mit ihnen **mehr als ein Viertel der Wohnbevölkerung**, laut Projektcode vor allem in den geteilten Bezirken der Innenstadt **ZUSATZ**. Eine Zuordnung, die stillschweigend Zeilen verliert, fällt in keiner Gütekennzahl auf. Sie muss beim Einlesen auffallen, oder sie fällt nie auf.

Dasselbe Muster wiederholt sich an jeder Nahtstelle: Vor jedem Verbund wird die Eindeutigkeit des Schlüssels geprüft, nach jedem die Zeilenzahl gegen den Erwartungswert gehalten. Davon getrennt hängt am Ende der Aufbereitung ein Katalog von 20 Einzelprüfungen, der unter anderem die beiden fertigen Analysedateien gegeneinander hält. Dazu kommen laut Projektcode zwei benannte Konstanten, die nicht eine Einstellung festhalten, sondern das erwartete Ergebnis **ZUSATZ**: dass genau 36 Stadtteile enthalten sind und dass die

stadtweite Einwohnerzahl in einer plausiblen Spanne liegt. Laut Arbeit liegt sie zwischen 811.572 und 856.270.

Was ausgeschlossen wurde, und warum als Ganzes

Fünf der 41 Stadtteile scheiden aus: die Parkanlagen Golden Gate Park, Lincoln Park und McLaren Park ohne nennenswerte Wohnbevölkerung sowie Lakeshore und Treasure Island, für die das Parzellenverzeichnis kein einziges Baujahr führt.

Entscheidend ist die *Form* dieses Ausschlusses: Entfernt werden vollständige Stadtteile, nie einzelne Monate. Ein zeilenweises Verwerfen erzeugt ein löchriges Raster, in dem ein Stadtteil mitten in der Zeitreihe hinzuträte. Umgekehrt bekommt jeder Monat ohne Einsatz eine Zeile mit dem Wert null — nicht gar keine Zeile. Ein rechteckiges Raster ist die Voraussetzung dafür, dass die fünf Prüfgruppen aus Band 1 überhaupt miteinander vergleichbar sind.

Am Ende stehen 4.752 Zeilen für die Menge und 4.751 für die Art — dem Strukturdatensatz fehlt der eine Monat ohne Einsatz, weil sich ihm keine überwiegende Einsatzart zuordnen lässt.

TEIL 7

Warum 4.752 Zeilen nur 39 Einheiten sind

Das ist die Grenze, auf die die Arbeit immer wieder zurückkommt. Sie erklärt, warum am Ende nur wenige Unterschiede zwischen den Verfahren statistisch absicherbar sind — und sie hat nichts damit zu tun, dass jemand schlecht gerechnet hätte.

Der Gedanke dahinter

Stellen Sie sich vor, Sie wollen wissen, wie groß erwachsene Menschen im Schnitt sind, und messen dafür eine Person 132-mal nach. Sie haben dann 132 Messwerte — aber Sie wissen noch immer nur, wie groß *eine* Person ist. Die 132 Zahlen sind nicht 132 unabhängige Informationen, sie sind eine, 132-mal wiederholt.

Genau in dieser Lage ist die Arbeit. Sie hat 36 Stadtteile über 132 Monate. Aber die meisten Merkmale eines Stadtteils bewegen sich zwischen Januar und Februar kaum. Drei von ihnen — die baulichen — sind über die vollen elf Jahre buchstäblich konstant. Und auch die Zahl der Einsätze schwankt von Monat zu Monat weit weniger als von Stadtteil zu Stadtteil. Die 132 Zeilen eines Stadtteils sind also zu einem großen Teil dieselbe Information, 132-mal wiederholt.

Wie stark, lässt sich messen. Das Maß heißt **Intraklassenkorrelation** und gibt an, wie stark zwei Monate desselben Stadtteils einander ähneln. Für die Einsatzhäufigkeit beträgt sie 0,926. Eng damit verwandt ist die Frage, wie viel der gesamten Schwankung *zwischen* den Stadtteilen liegt statt *innerhalb* eines Stadtteils über die Zeit: Es sind 92,5 % — die Zahl der Einsätze ist vor allem eine Sache des Ortes, nicht des Monats.

WIE VIEL UNABHÄNGIGE INFORMATION STECKT IN EINER SPALTE?

Rechnerisch entspricht der Bestand so vielen unabhängigen Beobachtungen:



Die drei baulichen Merkmale ändern sich in elf Jahren **gar nicht** — ihre 4.752 Zeilen tragen exakt 36 Informationen.

Abbildung 14: ZUSATZ Die effektive Stichprobengröße je Spalte, berechnet aus der Intraklassenkorrelation zwischen den Stadtteilen. Bei den beiden Saisontermen, die sich nur innerhalb eines Stadtteils bewegen, ergibt die Formel die vollen 4.752 Zeilen. Als unabhängige Information ist das nicht zu lesen: Die Saisonterme hängen allein am Kalendermonat, sind in allen 36 Stadtteilen gleich und nehmen im ganzen Datensatz nur elf verschiedene Werte an. Werte aus der Varianzzerlegung im Projektordner, gerundet; die Arbeit selbst nennt nur die rund 39 für die Einsatzhäufigkeit.

Aus der Intraklassenkorrelation der Einsatzhäufigkeit und der Zahl der Monate folgt der **Designeffekt** — der Faktor, um den man die Zeilenzahl herunterrechnen muss. Er beträgt hier 122. Und 4.752 geteilt durch 122 ergibt rund **39**.

Das ist keine Schätzung am Rande, sondern die Grenze, die die Arbeit für beide Fragestellungen zieht. Sie erklärt, warum die Aufteilung nach Stadtteilen erfolgt: Weil der Stadtteil die Einheit ist, nicht die Zeile. Und sie erklärt die nächste Zahl.

Was ein Test mit 39 Einheiten noch erkennen kann

Ein statistischer Test kann einen Unterschied übersehen, der wirklich da ist. Wie oft das passiert, hängt von zwei Dingen ab: wie groß der Unterschied ist und wie viel unabhängige Information vorliegt. Die Wahrscheinlichkeit, einen vorhandenen Unterschied auch zu finden, heißt **Trennschärfe**.

Die Arbeit rechnet sie für ihr eigenes Design aus — mit 4.000 simulierten Ziehungen. Das Ergebnis ist ernüchternd und sollte vor jeder Interpretation der p-Werte aus Band 1 stehen:

WIE WAHRSCHEINLICH FINDET DER TEST EINEN UNTERSCHIED, DEN ES WIRKLICH GIBT?




Abbildung 15: ZUSATZ Die Trennschärfekurve aus der Simulation der Arbeit (4.000 Ziehungen, zehn Paare); waagerecht die Effektstärke d , also der Abstand in Vielfachen der Streuung. Die drei Punkte markieren die gemessenen Abstände der drei Verfahren zur Poisson-Baseline bei der Anzahl ($d = 0,25, 0,52$ und $0,62$). Kurve und die Angabe „11 bis 40 %“ stammen aus der Trennschärfe-Auswertung im Projektordner; die Arbeit nennt für $d = 0,18$ bis $0,62$ einen Bereich von 8 bis 40 %. Alle signifikanten Vergleiche der Arbeit liegen bei $d \geq 0,84$ — eine feste Schwelle ist das aber nicht: Ridge gegen Random Forest verfehlt auf der Rate mit $d = 1,00$ die Signifikanz.

WAS DARAUS FÜR BAND 1 FOLGT

Die drei nicht signifikanten Vergleiche gegen die Baseline — Ridge mit $p = 0,275$, Random Forest mit $0,922$, XGBoost mit $0,275$ — sind **keine Aussage über Gleichheit**. Sie sind eine Aussage über die Auflösung dieses Designs — so formuliert es die Arbeit selbst. Bei den drei gemessenen Abständen hätte der Test einen echten Unterschied dieser Größe in 60 bis 89 % der Fälle gar nicht bemerkt **ZUSATZ**.

Was *doch* signifikant wird, ist dagegen ein großer Abstand: Ridge gegen XGBoost liegt bei $d = 1,57$. Einen so großen Unterschied hätte der Test ohne Korrektur für den Mehrfachvergleich mit 99 % Wahrscheinlichkeit gefunden; mit der Holm-Korrektur, die die Arbeit für diesen Vergleich anwendet, sind es immer noch mindestens rund 80 % **ZUSATZ**. Er hält in allen zehn Neuaufteilungen derselben 30 Stadtteile — ob er auf weiteren Stadtteilen hielte, sagt der Test allerdings nicht.

Warum die Arbeit nicht einfach mehr Daten nimmt

Der naheliegende Einwand lautet: Dann rechnet man eben über einen längeren Zeitraum. Die Arbeit entkräftet ihn in einem Satz — ein zusätzliches Jahr brächte 432 weitere Zeilen und **keinen einzigen weiteren Stadtteil**. Die Einheit ist der Ort, und von Orten gibt es 36.

Es gibt noch eine zweite Stelle, an der dieselbe Logik greift. Die Arbeit bewertet 50 Rechenläufe, testet aber nur auf zehn Werten. Der Grund ist derselbe: Die 50 Läufe sind dieselben 30 Stadtteile in wechselnder Gruppierung; ihre Übungsmengen überlappen einander. Sie als 50 unabhängige Messungen zu behandeln, wäre **Pseudoreplikation** — man täte so, als hätte man weit mehr unabhängige Information, als tatsächlich vorliegt. Die Arbeit verzichtet deshalb bewusst auf Trennschärfe und testet auf den zehn Wiederholungsmitteln. Der Preis dafür ist genau die geringe Auflösung, die Abbildung 15 zeigt. Ganz unabhängig sind allerdings auch die zehn Mittel nicht: Alle zehn prüfen dieselben 30 Stadtteile.

Noch eine Grenze: Das Modell wird nach Unbekanntem gefragt

Ein Entscheidungsbaum kann nur Werte vorhersagen, die er im Training gesehen hat. Bekommt er einen Stadtteil vorgelegt, dessen Armutsquote höher liegt als alles, was in seinen Übungsdaten vorkam, behandelt er ihn wie die Randfälle seiner Übungsdaten: Er sagt den Wert der äußersten Region voraus, die er kennt. Das nennt man **Extrapolation** — und die Arbeit misst, wie oft das passiert.

DIE 30 ENTWICKLUNGSSTADTTEILE — ANTEIL DER ZEILEN AUßERHALB DES GELERNTEN BEREICHS

100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	45 %	0 %	0 %	0 %
0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %	0 %

Kaum Zwischenstufen: Bei 11 der 30 Stadtteile liegt jede Zeile mit mindestens einem Merkmal außerhalb dessen, was das Modell gelernt hat — darunter Tenderloin und Seacliff, die beiden Extreme der Stadt.

Abbildung 16: ZUSATZ Jede Kachel ist ein Stadtteil in der ersten Wiederholung. Als außerhalb zählt eine Zeile, sobald mindestens eines ihrer zwölf Merkmale außerhalb des Bereichs der Übungsdaten liegt. Über alle fünfzig Läufe liegen 36,6 % der Testzeilen außerhalb des gelernten Bereichs, auf den sechs zurückgehaltenen Stadtteilen 34,8 %. Die beiden Gesamtwerte stehen in Tabelle 16 der Arbeit, die Kachelwerte im Projektordner; die Kachelanordnung ist frei gewählt.

Bemerkenswert daran ist, was *nicht* folgt. Man würde erwarten, dass gerade die Baumverfahren darunter leiden, weil nur sie diese Schwäche haben. Gemessen ist etwas anderes: Der Zusammenhang zwischen dem Extrapolationsanteil eines Laufs und dem dort erreichten Fehler ist bei Ridge und XGBoost ähnlich eng (+0,335 und +0,353) und beim Random Forest am schwächsten (+0,249). Wäre die Extrapolation der Hebel gegen die Baumverfahren, müsste er bei ihnen enger sein als bei Ridge. Sie erklärt deren Rückstand also nicht — was bleibt, ist eine Eigenschaft des Prüfrahmens selbst.

TEIL 8

Überanpassung — wenn ein Modell auswendig lernt

In Band 1 stand dieser Begriff im Glossar und danach kaum wieder. Dabei hilft er, einen der überraschendsten Befunde der Arbeit einzuordnen: dass die aufwendigen Verfahren ein schlichtes Modell nicht übertreffen.

Zwei Zahlen, die man nebeneinander lesen muss

Für jedes Verfahren gibt es zwei Güteangaben. Die eine sagt, wie gut es die *Übungsstadtteile* beschreibt, die es kennt. Die andere, wie gut es die *Prüfstadtteile* trifft, die es nie gesehen hat. Bei einem Schüler wären das die Hausaufgaben und die Klausur.

Solange beide Werte nah beieinanderliegen, hat das Modell etwas verstanden. Klafft eine Lücke, hat es auswendig gelernt.

ERKLÄRTE SCHWANKUNG — AUF DEN ÜBUNGSSTADTTEILEN GEGEN NEUE STADTTEILE




Abbildung 17: Werte aus Abschnitt 6.1 und Tabelle 9 der Arbeit. Alle drei Verfahren verlieren beim Sprung auf unbekannte Stadtteile — die beiden Baumverfahren aber rund zweieinhalbmals so viel wie Ridge.

Was daran auffällt

Auf den Übungsstadtteilen sind die Baumverfahren *besser* als Ridge: 0,965 und 0,975 gegen 0,842. Auf neuen Stadtteilen sind sie *schlechter*: 0,498 und 0,486 gegen 0,655. Beide Aussagen stammen aus demselben Rechenlauf.

Das passt zum Ergebnis aus Band 1. Die Baumverfahren nutzen ihre Flexibilität — sie bilden die 24 Übungsstadtteile fast perfekt nach. Die Lücke zu den neuen Stadtteilen zeigt aber, was die Arbeit an anderer Stelle so zusammenfasst: Was im Training besser aussieht, trägt auf neuen Stadtteilen nicht.

Auch in der Schlussbewertung zeigt sich diese Lücke: Dort erreicht XGBoost auf seinen Trainingsdaten ein Bestimmtheitsmaß von **0,997** **ZUSATZ** — es beschreibt die 30 Entwicklungsstadtteile praktisch fehlerfrei. Auf den sechs unbekannten kommt es auf 0,691 und ist damit dort trotzdem das beste der Verfahren.

WARUM DAS KEIN BEDIENFEHLER IST

Man könnte denken, die Bremsen seien schlecht eingestellt. Dagegen spricht, dass die Arbeit für jedes Verfahren 100 Einstellungskombinationen durchprobiert hat, und zwar für jede Prüfgruppe einzeln — und gewählt wurde jeweils die Kombination, die auf zurückgehaltenen Übungsstadtteilen am besten abschnitt, nicht die, die die Übungsdaten am genauesten nachbildet. Die Lücke bleibt trotzdem. Naheliegend ist, dass sie mit der Datenlage aus Teil 7 zusammenhängt: Bei 24 Übungsstadtteilen gibt es wenig, aus dem sich eine übertragbare Regel gewinnen ließe, und viel, das sich auswendig lernen lässt.

Bei der Einsatzart wiederholt sich das Muster in kleinerem Maßstab **ZUSATZ**: Der Random Forest erreicht auf den Übungsdaten ein Macro-F1 von 0,582 und auf neuen Stadtteilen 0,318, XGBoost 0,480 gegen 0,301.

TEIL 9

Durften diese Verfahren überhaupt antreten?

Bevor die Verfahren angepasst wurden, hat die Arbeit geprüft, ob die Daten zu ihnen passen. Das Ergebnis dieser Prüfung ist nicht nur formal interessant — es steht in einem lehrreichen Widerspruch zu dem, was am Ende herauskam.

Die Ausgangslage

Die Beweislast liegt bei den aufwendigen Verfahren. Das schlichte Poisson-Modell funktioniert bereits; wer mehr Aufwand treiben will, muss begründen, warum. Die Frage ist dabei nicht, *ob* das lineare Modell rechnet, sondern ob seine Bauform zur Struktur der Daten passt. Sie unterstellt zwei Dinge: dass jedes Merkmal über seinen gesamten Wertebereich gleich wirkt, und dass diese Wirkung nicht davon abhängt, welche Werte die anderen Merkmale annehmen.

Beides hält einer Prüfung nicht stand — und die Arbeit prüft es mit benannten Verfahren statt nach Augenmaß.

ZWÖLF ANFORDERUNGEN — TESTS AUF DEN 24 ÜBUNGSSTADTEILEN DER ERSTEN PRÜFGRUPPE

- **Unabhängige Beobachtungen — verletzt**
betrifft alle fünf Verfahren gleichermaßen · Folge: Aufteilung nach Stadtteilen statt zufällig (Teil 7)
- **Gleiche Höhe und Streuung der Zählgröße — verletzt, Teststatistik 18,0**
die Varianz ist rund 80-mal so groß wie der Mittelwert · Folge: folgenlos, da nur Punktvorhersagen berichtet werden
- **Gerader Zusammenhang zwischen Merkmalen und Ziel — verletzt, Teststatistik 360,4**
betrifft Poisson-Modell und Ridge · Folge: genau hier setzen die Baumverfahren an
- **Gleichmäßige Fehlerstreuung — verletzt, Teststatistik 525,1**
Folge: betrifft die Unsicherheitsangaben, nicht die Vorhersage selbst — und diese Angaben werden hier nicht berichtet
- **Testpunkte im gelernten Wertebereich — verletzt, im Mittel 38,2 % außerhalb**
betrifft Random Forest und XGBoost · Folge: als Limitation ausgewiesen (Abbildung 16)
- **Erfüllt oder nicht erforderlich: identische Daten für alle Verfahren, Normalverteilung der Fehler, Verteilungsannahme der Baumverfahren, passende Verlustfunktion, jede Klasse in jeder Prüfgruppe**

Abbildung 18: Tabelle 7 der Arbeit, zusammengefasst. Von zwölf Anforderungen sind sechs verletzt und zwei für das jeweilige Verfahren gar nicht zu stellen. Die Folgen sind verschieden: Eine Verletzung betrifft alle Verfahren gleich, zwei betreffen nur die *Unsicherheitsangaben*, drei die Vorhersage selbst. Die gerade Form beim Logit prüft die Arbeit nicht eigens; das klärt der Vergleich. Die Teststatistiken sind auf den 24 Übungsstadtteilen der ersten Prüfgruppe gerechnet, die 38,2 % dagegen sind ein Mittel über alle fünf Prüfgruppen der ersten Wiederholung.

Zwei Ursachen, benannt

Krümmung. Der Zusammenhang zwischen Merkmal und Zielgröße verläuft nicht gerade. Der verwendete Test nimmt die Vorhersagewerte des Modells, fügt ihr Quadrat als zusätzliches Merkmal hinzu und misst, ob die Anpassung dadurch besser wird. Sie wird deutlich besser. Einen Hinweis, wo die Krümmung steckt, gibt ein schlichterer Vergleich auf den 24 Übungsstadtteilen: Bei der Wohnbevölkerung liegt das Rangmaß mit +0,744 deutlich über dem geradlinigen Zusammenhangsmaß mit +0,532 — die Einsätze steigen mit der Bevölkerung, aber nicht gleichmäßig. Bei der Armutsquote ist es umgekehrt, +0,617 geradlinig gegen +0,342

im Rang; das deutet eher auf einzelne Stadtteile, die die Gerade an sich ziehen. (Tabelle 4 der Arbeit nennt andere Werte, weil sie über alle 36 Stadtteile gerechnet ist.)

Wechselwirkungen. Ergänzt man das lineare Modell um alle 45 paarweisen Produkte der zehn Merkmale, steigt die bereinigte erklärte Schwankung (das adjustierte Bestimmtheitsmaß) von 0,859 auf 0,932. Es gibt also Zusammenspiele, die ein rein additives Modell nicht erfasst.

Aus beidem folgt genau die Verfahrenswahl der Arbeit: Ein lineares Modell braucht für Krümmung vorab festgelegte Transformationen und für Wechselwirkungen von Hand eingefügte Produktterme — für deren Auswahl es keine Regel gibt. Baumverfahren brauchen beides nicht. Die linearen Verfahren scheiden damit aber nicht aus — entscheiden muss der Vergleich.

UND JETZT DER WIDERSPRUCH

Die Eignungsprüfung sagt: Die lineare Form reicht nicht. Das Ergebnis aus Band 1 sagt: Ridge sagt unbekannte Stadtteile in der Kreuzvalidierung trotzdem am genauesten vorher.

Die Arbeit zeigt, warum das kein Widerspruch sein muss. Beide Befunde der Eignungsprüfung beziehen sich auf *dieselben Zeilen, an denen das Modell angepasst wurde*. Sie belegen, dass die lineare Form die vorliegenden Stadtteile schlechter beschreibt als eine flexiblere Form — nicht, dass sie unbekannte Stadtteile schlechter *vorhersagt*. Das sind zwei verschiedene Aussagen, und die Gegenprobe aus Band 1 (Abbildung 12) zeigt, dass sie hier sogar gegenläufig ausfallen: Jede Erweiterung, die das Modell besser *beschreiben* lässt, macht seine Vorhersagen dramatisch schlechter.

Daraus zieht die Arbeit ihre übertragbare Regel: Nachweisbare Nichtlinearität im Anpassungsdatensatz begründet für sich genommen noch kein flexibleres Verfahren — solange der Nachweis die Monatswerte eines Stadtteils als unabhängig behandelt.

Was ausdrücklich nicht verglichen wurde

Zur Eignungsprüfung gehört auch die umgekehrte Begründung. Lasso und Elastic Net scheiden aus, weil sie Koeffizienten auf null setzen und damit Merkmale aussortieren — im Vergleich soll sich aber nur das Verfahren ändern, nicht der Merkmalssatz. Neuronale Netze scheiden aus, weil 36 Analyseeinheiten für sie zu wenig sind. Und die Ridge Regression tritt bei der Einsatzart nicht an: Auf Kategorien angewendet, lieferte sie Werte unter null oder über eins, also keine Wahrscheinlichkeiten, und das passende lineare Verfahren für Kategorien — das Logit — ist dort bereits der Maßstab.

Was die Suche nach den Einstellungen wirklich findet

Bevor die Verfahren bewertet werden, steht eine Suche: Welche Einstellungen soll das Verfahren bekommen? Sie ist der größte Einzelposten des Rechenaufwands — 25 Suchläufe, 10.000 Modellanpassungen, rund 137 Minuten. Und sie fördert etwas zutage, das man nicht erwartet.

Wie gesucht wird

Die *Hyperparameter* dürfen die Prüfdaten nicht kennen. Gesucht wird deshalb in einer *zweiten, inneren* Aufteilung innerhalb der Übungsstadtteile: Vier innere Gruppen, wieder nach Stadtteilen getrennt, wieder so, dass ein Stadtteil mit allen 132 Monaten entweder im inneren Training oder in der inneren Prüfung steht — nie in beidem. Gesucht wird je Prüfgruppe, und zwar nur in der ersten der zehn Wiederholungen; die übrigen neun übernehmen die gefundenen Parametersätze.


Gezogen wird zufällig, hundertmal je Suchlauf. Warum hundert und nicht fünfzig, ist ausgerechnet und nicht geraten: Mit hundert zufälligen Ziehungen trifft man einen Zielbereich, der fünf Prozent des Suchraums ausmacht, mit 99,4 % Wahrscheinlichkeit mindestens einmal — bei fünfzig sind es 92,3 %.

Auf den ersten Blick wirkt das ungleich: Ridge hat **einen** einstellbaren Parameter, XGBoost hat **sieben**, und beide bekommen dasselbe Budget von hundert Ziehungen. Man könnte meinen, hundert Versuche deckten einen Raum mit sieben Stellschrauben deutlich dünner ab als einen mit einer. Die Arbeit hält dagegen, dass die Rechnung oben nicht von der Zahl der Stellschrauben abhängt, sondern nur davon, welchen Anteil des Suchraums der Bereich guter Werte ausmacht. Ob dieser Anteil bei sieben Stellschrauben ebenso groß ist wie bei einer, sagt die Rechnung allerdings nicht **ZUSATZ**. Dass daraus kein messbarer Nachteil für XGBoost entsteht, zeigt die Suchdiagnose weiter unten.

Der eigentliche Befund

Die Suche liefert je Prüfgruppe einen eigenen Parametersatz — fünf Sätze insgesamt. Eine naheliegende Gegenprobe: Was passiert, wenn man jede Prüfgruppe nicht mit *ihrem* Satz bewertet, sondern mit einem, der auf ganz anderen Stadtteilen gefunden wurde?

FEHLER MIT DEM EIGENEN GEGEN EINEN FREMDEN PARAMETERSATZ (RMSE)



Bei beiden Baumverfahren ist der eigens gesuchte Satz im Mittel **schlechter** als ein auf fremden Daten gefundener.

Abbildung 19: ZUSATZ Jede Prüfgruppe wurde mit jedem der fünf gefundenen Parametersätze bewertet. Werte aus der Parametersensitivität im Projektordner, erste Wiederholung — sie liegen deshalb nicht exakt auf den Hauptergebnissen aus Band 1. Bei Ridge ist der fremde Satz in 10 von 20 Paarungen besser, in 4 schlechter und in 6 gleich, weil drei Prüfgruppen dasselbe Strafgewicht gewählt haben; im Mittel liegt trotzdem der eigene knapp vorn.

Das Ergebnis ist bemerkenswert: Beim Random Forest ist der eigens gesuchte Satz im Mittel um 1,85 RMSE *schlechter* als ein fremder, bei XGBoost um 1,05. Nur bei Ridge bringt er einen kleinen Vorteil von 0,46, und der geht fast ganz auf eine einzige Prüfgruppe zurück.


Man kann das auch von der anderen Seite betrachten: Innerhalb *derselben* Prüfgruppe trennen die fünf Parametersätze im Mittel bei Ridge 2,54 RMSE, beim Random Forest 4,91 und bei XGBoost 9,14. Zum Vergleich: Der gesamte Abstand zwischen dem besten und dem schwächsten Verfahren beträgt 6,46. Die Wahl des Parametersatzes bewegt das Ergebnis bei XGBoost also stärker als die Wahl des Verfahrens.

Woher das kommt

Nicht aus einer schlechten Suche. Die Arbeit prüft das eigens: Eine Diagnose schreibt jede der hundert Ziehungen mit ihrem inneren Gütewert mit. Die zweite Hälfte der Suche verbessert den bis dahin besten Wert bei keinem der fünf gesuchten Modelle im Mittel um mehr als 0,020 — gemessen an einer Streuung zwischen den Prüfgruppen, die für dieselben Modelle zwischen 0,040 und 0,342 liegt. Die Suche war ausgereizt, lange bevor das Budget aufgebraucht war.

Die Ursache ist wieder Teil 7. Die innere Suche rechnet auf nur 24 Stadtteilen, und schon der ganze Datensatz trägt nur rund 39 unabhängige Einheiten. Der innere Gütewert schwankt deshalb stärker, als die Unterschiede zwischen den Parametersätzen groß sind. Welcher Parametersatz in der Suche vorn liegt, hängt dann zum Teil vom Zufall ab.

WIE TIEF SOLLEN DIE BÄUME WACHSEN? — DIE ANTWORT JE PRÜFGRUPPE, EINSATZART



Dieselben 30 Stadtteile, nur anders gruppiert. In zwei Gruppen wählt die Suche 48 Ebenen, die tiefste feste Stufe, in zwei anderen die flachste Stufe mit 8 Ebenen. Ein Verfahren, zwei entgegengesetzte Antworten.

Abbildung 20: ZUSATZ Die vom Random Forest gewählte Baumtiefe im Strukturstrang, je Prüfgruppe. Die Spanne von 8 bis 48 Ebenen steht in Tabelle 8 der Arbeit, die Werte je Prüfgruppe im Projektordner. XGBoost wählt im selben Strang dagegen flache Bäume mit 1 bis 9 Ebenen; seine Strafterme reichen dort von 1,7 bis 9.333.

Dazu passt eine Folgerung, die die Arbeit aus dem Rechenaufwand der Suche zieht — rund 137 Minuten, davon nur 36 Sekunden für Ridge: Der Aufwandsnachteil der Baumverfahren entsteht nicht erst beim fertigen Modell, sondern vervielfacht sich über die Modellwahl. Und welcher Parametersatz dabei vorn liegt, hängt zum Teil vom Zufall ab.

TEIL 11

Verteilen sich die Fehler gerecht?

Ein Modell kann im Durchschnitt gut sein und trotzdem systematisch bei bestimmten Stadtteilen danebenliegen. Wenn diese Stadtteile die ärmeren sind, ist das mehr als ein statistisches Detail. Eine Zusatzauswertung im Projektordner prüft das — und findet etwas Unbequemes.

ZUSATZ Dieser ganze Teil beruht auf einer archivierten Zusatzauswertung im Projektordner (Fairness-Auswertung). In der Arbeit selbst wird sie nicht berichtet.


Die Frage und ihre Tücke

Gemessen wird, ob in Prüfgruppen mit höherer Armutsquote auch der Prognosefehler höher ausfällt. Der Zusammenhang besteht — für jedes einzelne Verfahren und beide Mengenzielgrößen, deutlich, mit Rangkorrelationen zwischen +0,39 und +0,81.

Das allein besagt jedoch wenig. In ärmeren Stadtteilen finden schlicht *mehr* Einsätze statt, und ein größerer absoluter Fehler bei gleicher relativer Genauigkeit ist keine Benachteiligung. Wer 200 Einsätze vorhersagt und 20 danebenliegt, ist genauso gut wie jemand, der bei 20 Einsätzen 2 danebenliegt.

Die aussagekräftige Rechnung setzt den Fehler deshalb ins Verhältnis zur mittleren Einsatzzahl der Prüfgruppe. Erst dann zeigt sich, ob wirklich ungleich gut vorhergesagt wird.

ZUSAMMENHANG ZWISCHEN ARMUTSQUOTE DER PRÜFGRUPPE UND PROGNOSEFEHLER



Je länger der untere Balken, desto stärker hängt die Qualität vom Sozialprofil ab. Null wäre Gleichbehandlung.

Abbildung 21: Rangkorrelation über die fünfzig Läufe des Mengenstrangs, Zielgröße Anzahl Einsätze. Werte aus der archivierten Fairness-Auswertung im Projektordner, nicht aus der Arbeit.

Das unbequeme Ergebnis

Bei den beiden Baumverfahren verschwindet der Zusammenhang nach der Relativierung weitgehend — er sinkt auf +0,18 und +0,15 und ist statistisch nicht mehr absicherbar. Beim Poisson-Modell bleibt dagegen ein deutlicher Rest von +0,60, bei Ridge +0,30. Alle p-Werte gelten dabei nur nominell, weil die fünfzig Läufe dieselben Stadtteile in wechselnder Gruppierung sind (Teil 7).

Das heißt: **Ausgerechnet die Modelle, die im Mittel am genauesten vorhersagen, verteilen ihre Fehler am ungleichmäßigsten über das Sozialprofil der Stadtteile.** Und ausgerechnet die Verfahren, die in Band 1 den kürzeren gezogen haben, behandeln arme und reiche Stadtteile am ähnlichsten.

Bei der bevölkerungsnormierten Zielgröße fällt das Bild gleichsinnig aus: Poisson +0,41, Ridge +0,19, Random Forest +0,01, XGBoost +0,05.

WAS DIESER BEFUND IST — UND WAS NICHT

Geprüft ist die *Gleichheit der Fehler*, nicht die Gerechtigkeit einer daraus abgeleiteten Zuteilung. Ob ein Modell, das in ärmeren Stadtteilen relativ ungenauer ist, dort am Ende zu wenig oder zu viel Ressourcen zuwies, hängt an der Richtung des Fehlers und an der Entscheidungsregel darüber — beides untersucht die Arbeit nicht.

Der Befund ändert auch nichts an den Ergebnissen aus Band 1, denn eine Rangfolge zwischen den Verfahren lässt die Datenlage ohnehin nur eingeschränkt zu. Er ist ein zusätzlicher Gesichtspunkt, den man kennen sollte, bevor man eines dieser Modelle einsetzt.

Was so ein Modell dürfte – und was nicht

Beim Wort „Vorhersage“ denken viele an Polizeisoftware, die ausrechnet, wo als Nächstes ein Verbrechen passiert. Dieser Teil ordnet ein, was ein Modell wie das der Arbeit davon unterscheidet — und welche Grenzen die Arbeit selbst zieht.

Der Unterschied, auf den es ankommt

ZUSATZ Diese Einordnung geht über die Arbeit hinaus und lässt sich auf eine Formel bringen: **Ein Modell, das Einsatzlast vorhersagt, dient der Verteilung von Hilfe, nicht von Kontrolle.**

Ein zusätzlicher Löschzug nützt einem Stadtteil in aller Regel; zusätzliche Polizeistreifen können ihn auch belasten. In der Notfallversorgung ist eine Zuteilung nach vorhergesagtem Bedarf deshalb im Grundsatz gewollt. Bei der Polizei kann dieselbe Mechanik dagegen zu immer mehr Kontrolle in ohnehin stärker kontrollierten Vierteln führen; das zeigen Lum und Isaac (2016), eine Studie, die die Arbeit an anderer Stelle zitiert.

Diese Einordnung hat allerdings eine Bedingung **ZUSATZ**: Sie gilt nur, *solange der Bedarf nicht über einen Indikator geschätzt wird, dessen Höhe selbst von einer Zuteilung abhängt* — etwa davon, wo die Polizei kontrolliert. Genau hier wird es heikel — denn ohne den Kriminalitätsindex wird die Vorhersage der Einsatzzahl in der Arbeit schlechter als ohne jede andere Merkmalsgruppe, und dieser Index stammt aus polizeilichen Meldungen.

WOHER DER KRIMINALITÄTSINDEX WIRKLICH KOMMT

Er stammt aus polizeilichen Meldungen. Polizeiliche Register sind weder eine Vollerhebung aller Delikte noch eine repräsentative Stichprobe daraus, wie Lum und Isaac festhalten **ZUSATZ**. Sie hängen nicht nur vom tatsächlichen Tatgeschehen ab, sondern auch von der Bereitschaft der Anwohner, etwas anzuzeigen, und von der Intensität, mit der die Polizei dort kontrolliert — das hält auch die Arbeit fest.

Belegt ist deshalb **nicht**, dass Kriminalität Feuerwehreinsätze erklärt. Belegt ist nur, dass die Vorhersage der Einsatzzahl ohne die *registrierte* Kriminalitätsbelastung schlechter wird als ohne jede andere Merkmalsgruppe. Das ist eine schwächere und ehrlichere Aussage.

Was die Arbeit ausdrücklich nicht tut

Drei Abgrenzungen stehen bereits in Kapitel 4 der Arbeit, also vor dem ersten Ergebnis:

- **Kein Ursachenanspruch.** Geprüft wird, ob die Merkmale einen Beitrag zur Vorhersage leisten — nicht, ob sie Einsätze verursachen.
- **Keine Empfehlung zur Verteilung von Einsatzmitteln.** Die wäre ein eigener Schritt mit eigenen Voraussetzungen.
- **Keine Aussage über einzelne Gebäude oder Haushalte.** Die Ergebnisse gelten auf der Ebene des Stadtteils, und nur dort.

Zur zweiten Abgrenzung gehört eine Begründung, die leicht übersehen wird: Sozioökonomische Merkmale können als **Stellvertreter geschützter Eigenschaften** wirken. Merkmale wie die Armutsquote stehen dann nicht nur für sich, sondern können mit Eigenschaften zusammenhängen, nach denen nicht unterschieden werden darf. Die Übersetzung eines solchen Modells in Ressourcenentscheidungen erfordert deshalb eine eigene Prüfung — die diese Arbeit nicht leistet und auch nicht beansprucht zu leisten.

Fünf Grenzen, die man mitdenken muss

GRENZE	WAS GEMESSEN IST
Zu wenige Einheiten	36 Stadtteile, effektiv rund 39 unabhängige Einheiten — ein längerer Zeitraum ändert daran nichts (Teil 7)
Extrapolation	36,6 % der Testzeilen liegen außerhalb des gelernten Bereichs, auf dem Hold-out 34,8 %
Die seltene Klasse	33 branddominierte Monate in den 30 Entwicklungsstadtteilen (insgesamt 70), 2 bis 13 je Prüfgruppe — ein Viertel des Leitmaßes ruht darauf
Zeitliche Auflösung	Sozialdaten in vier Jahrgängen mit Versatz, Flächennutzung als einzige Momentaufnahme von 2020
Gebietszuschnitt	36 Stadtteile statt 242 kleinerer Bezirke — eine andere Einteilung kann eine andere Rangfolge liefern

Auswahl aus Abschnitt 7.3 und Tabelle 16 der Arbeit; die Tabelle selbst nennt neun Grenzen.

Zwei weitere Punkte sind zu konkret, um sie wegzulassen. Erstens folgen die Prüfgruppen der Verwaltungsgrenze und nicht der Reichweite räumlicher Abhängigkeit. Ein Sicherheitsabstand um die Prüfstadtteile herum ließe im Mittel nur 8,6 statt 24 Übungsstadtteile übrig — darauf verzichtet die Arbeit, und deshalb fällt der berichtete Fehler eher zu klein als zu groß aus.

Zweitens ist die Bezugsgröße die *Wohnbevölkerung*. Für die Innenstadt ist das unvollständig: Financial District/South Beach hat eine mittlere Wohnbevölkerung (20.044 Einwohner **ZUSATZ**), aber mit 10,40 Einsätzen je 1.000 Einwohner die höchste Rate der Stadt — knapp das Vierfache des Medians der Stadtteile **ZUSATZ**. Die Arbeit vermutet, dass diese Last zu einem guten Teil von Pendlern und Besuchern stammt, die in keiner Einwohnerzahl auftauchen.

Und die Antwort auf die Ausgangsfrage

Für die Modellwahl zieht die Arbeit einen knappen Schluss: Wo sich kein Verfahren von der Referenz trennen lässt, gibt es keinen Grund, über sie hinauszugehen — ein aufwendigeres Verfahren wäre hier nicht falsch, nur unwirtschaftlich. Und für die Praxis gilt: Die Prognose trennt Stadtteile nach ihrer Last, aber nicht einzelne Monate eines Stadtteils. Welche Stadtteile über- und welche unterdurchschnittlich belastet sind, lässt sich aus den Merkmalen ableiten; die konkrete Einsatzzahl eines einzelnen Stadtteilmonats dagegen nur mit einem mittleren Fehler von rund 20 Einsätzen.

Die neuen Fachbegriffe

Vor allem Begriffe, die in Band 1 noch nicht vorkamen, dazu einer aus Band 1. Wie dort: eine kurze Erklärung und ein Beispiel aus dieser Arbeit.

Datenleckage

Ein Modell rechnet mit Informationen, die es zum Zeitpunkt der Vorhersage noch gar nicht geben konnte — es liest die Antwort ab, statt sie zu erraten.

HIER: Die Antwortzeit eines Einsatzes steht erst nach dem Einsatz fest. Laut Projektcode ist sie eines der zehn Felder, die gesperrt wurden **ZUSATZ**.

Publikationsversatz

Der Abstand zwischen dem Zeitraum, den eine Statistik beschreibt, und dem Zeitpunkt, an dem sie veröffentlicht wird.

HIER: Für einen Einsatz im Jahr 2020 durfte höchstens der Sozialdaten-Jahrgang 2019 verwendet werden.

Crosswalk

Eine Übersetzungstabelle zwischen zwei unterschiedlichen Gebietseinteilungen.

HIER: Sie ordnet die kleinen statistischen Bezirke den 41 Stadtteilen zu — je Jahrgang gelingt das für 99,2 bis 99,5 % der Bezirke.

Standortquotient

Ein Wert, der eine Größe nicht absolut misst, sondern im Verhältnis zum Durchschnitt des Ganzen. Eins bedeutet „genau wie der Durchschnitt“.

HIER: Der Kriminalitätsindex setzt die Deliktrate eines Stadtteils über die zwölf Vormonate ins Verhältnis zur Rate der Gesamtstadt. Hebt oder senkt ein Wechsel des polizeilichen Erfassungssystems die Zahlen aller Stadtteile im gleichen Verhältnis, fällt dieser gemeinsame Faktor dadurch heraus; Verschiebungen, die einzelne Stadtteile stärker treffen, bleiben enthalten.

Intraklassenkorrelation

Wie stark zwei Messungen derselben Gruppe einander ähneln — eng verwandt mit dem Anteil der Schwankung, der *zwischen* den Gruppen liegt statt innerhalb einer Gruppe.

HIER: 0,926 für die Einsatzhäufigkeit — die Zahl der Einsätze hängt weit mehr daran, welcher Stadtteil es ist, als daran, welcher Monat.

Designeffekt und effektive Stichprobe

Der Faktor, um den man die Zeilenzahl herunterrechnen muss, weil die Zeilen einander ähneln — und das Ergebnis dieser Rechnung.

HIER: Designeffekt 122, also 4.752 geteilt durch 122 und damit rund 39 unabhängige Einheiten. Auf diese Grenze kommt die Arbeit an vielen Stellen zurück.

Pseudoreplikation

Der Fehler, abhängige Messungen als unabhängig zu behandeln — man tut so, als hätte man mehr Information, als man hat.

HIER: Die Arbeit vermeidet ihn bewusst: Sie rechnet 50 Läufe, testet aber nur auf zehn Werten, weil die 50 Läufe dieselben 30 Stadtteile in wechselnder Gruppierung sind.

Trennschärfe

Die Wahrscheinlichkeit, dass ein statistischer Test einen Unterschied findet, den es wirklich gibt.

HIER: Bei den drei gemessenen Abständen zur Baseline bei der Anzahl nur 11 bis 40 % **ZUSATZ**; die Arbeit nennt für Abstände dieser Größenordnung 8 bis 40 %. Deshalb heißt „nicht signifikant“ in dieser Arbeit vor allem „nicht auflösbar“.

Extrapolation

Ein Modell wird nach einem Wert gefragt, der außerhalb von allem liegt, was es im Training gesehen hat.

HIER: In der ersten Wiederholung liegt bei 11 der 30 Stadtteile jede Zeile mit mindestens einem Merkmal außerhalb des gelernten Bereichs **ZUSATZ** — für dieses Merkmal behandelt ein Baum sie wie die Randfälle seiner Übungsdaten, mehr kann er nicht.

Hyperparameter (aus Band 1)

Einstellungen, die vorab festgelegt werden müssen, weil ein Verfahren sie nicht selbst aus den Daten lernen kann.

HIER: Ridge hat einen einzigen, XGBoost hat sieben. Die beiden Baselines haben keinen — das gehört zu den Gründen, warum sie als Messlatte taugen.

Rangkorrelation

Ein Maß dafür, ob zwei Größen in derselben Reihenfolge verlaufen — ohne anzunehmen, dass der Zusammenhang gerade ist. Null heißt kein Zusammenhang, eins heißt gleiche Reihenfolge.

HIER: +0,60 zwischen der Armutsquote einer Prüfgruppe und dem relativen Fehler des Poisson-Modells **ZUSATZ** — tendenziell: je ärmer, desto ungenauer.

Stellvertretermerkmal

Ein Merkmal, das formal etwas anderes misst, in der Sache aber eng mit einer geschützten Eigenschaft zusammenhängt.

HIER: Die sozioökonomischen Merkmale, etwa die Armutsquote. Die Arbeit nennt das als Grund, warum ihre Ergebnisse nicht ohne eigene Prüfung in Ressourcenentscheidungen übersetzt werden sollten.

Grundlage dieses Bandes: Bachelorarbeit „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und sozioökonomischer Merkmale – ein Vergleich ausgewählter Machine-Learning-Methoden am Beispiel von Stadtteildaten“ (Fassung vom 5. Oktober 2026), insbesondere die Abschnitte 3.2, 4.1 bis 4.5, 5.1 bis 5.3, 6.1 bis 6.5, 7.2 und 7.3 sowie die Tabellen 3, 7 bis 10 und 16; ergänzend Code und Auswertungen im Projektverzeichnis — Aufbereitung, Varianzzerlegung, Suchdiagnose, Parametersensitivität, Trennschärfe, Extrapolation und die archivierte Fairness-Auswertung. Alle Zahlenwerte wurden gegen diese Quellen abgeglichen; Angaben, die nicht in der Arbeit stehen, sind mit **ZUSATZ** markiert. Wo die Arbeit eine Frage offen lässt, ist das im Text vermerkt und nicht geglättet. Die Abbildungen wurden eigens gezeichnet und sind keine Reproduktionen der Originalabbildungen.