

Kann man ausrechnen, wo die Feuerwehr gebraucht wird?

Eine Bachelorarbeit vergleicht fünf Rechenverfahren, die aus den Merkmalen eines Stadtteils vorhersagen sollen, wie viele Feuerwehreinsätze es dort geben wird — und welcher Art sie sind. Diese Zusammenfassung erklärt ohne Vorkenntnisse, was untersucht wurde und was herauskam.

Titel der Arbeit: „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und sozioökonomischer Merkmale – ein Vergleich ausgewählter Machine-Learning-Methoden am Beispiel von Stadtteildaten“

Autor: Lukas Nießen · FOM Hochschule, Wirtschaftsinformatik (B.Sc.)

Datengrundlage: San Francisco, Januar 2015 bis Dezember 2025

Markierung: **ZUSATZ** kennzeichnet Angaben, die nicht in der Arbeit stehen

TEIL 1

Aufbau der Arbeit

Die Feuerwehr muss entscheiden, wo sie Wachen, Fahrzeuge und Personal vorhält — und zwar lange bevor der erste Alarm eingeht. Die Arbeit prüft, ob sich der zu erwartende Einsatzbedarf eines Stadtteils allein aus dessen Merkmalen berechnen lässt: Einkommen, Armut, Leerstand, Baujahr der Häuser, Kriminalitätsbelastung. Also aus Daten, die es auch dort gibt, wo noch keine brauchbare Einsatzstatistik vorliegt.

Die Fragestellung

Warum das wichtig ist, steht gleich am Anfang der Arbeit: Wie viel eine Feuerwehr im Ernstfall ausrichtet, hängt an der Zeit bis zum Eintreffen. Für Wohnungsbrände ist der Zusammenhang zwischen dieser Hilfsfrist und der Zahl der Todesopfer nachgewiesen. Diese Zeit entscheidet sich aber nicht im Einsatz, sondern vorher — bei der Frage, wo eine Wache steht und wie viele Kräfte dort bereitstehen.

Die Arbeit sagt dabei ausdrücklich *nicht* vorher, wann und wo ein konkreter Brand ausbricht. Das ginge aus Strukturmerkmalen nicht. Vorhergesagt wird das *Niveau*, auf dem sich die Einsatzlast eines Stadtteils bewegt. Und zwar in zwei Hinsichten:

Frage 1: WIE VIELE?

Wie viele Einsätze hat dieser Stadtteil in diesem Monat?

Antwort ist eine Zahl: 0, 1, 2, ... 451

Seacliff, Monatsmittel:	6
Tenderloin, Monatsmittel:	280

Solche Aufgaben heißen **Regression**.

Frage 2: WELCHE ART?

Welche Einsatzart überwiegt in diesem Stadtteil-Monat?

Antwort ist eine von vier Schubladen

Fehlalarm	technische Hilfe
Rettungsdienst	Brand

Solche Aufgaben heißen **Klassifikation**.

Abbildung 1: Die Arbeit beantwortet zwei verschiedene Fragen über denselben Stadtteil. Die eine verlangt eine Zahl, die andere eine Kategorie. Das sind zwei unterschiedliche Aufgabentypen, und sie brauchen je eine eigene Baseline, eine eigene Verlustfunktion und eigene Bewertungsmaßstäbe; Random Forest und XGBoost treten bei beiden an. Die Zahlen im Beispiel sind das kleinste und das größte Monatsmittel eines Stadtteils aus der Arbeit (6,4 bzw. 279,7 Einsätze je Monat, hier gerundet).

Die zentrale Forschungsfrage der Arbeit lautet sinngemäß: Inwiefern lassen sich Häufigkeit und Art der Feuerwehreinsätze in den Stadtteilen San Franciscos durch sozioökonomische, kriminalitätsbezogene und bauliche Merkmale statistisch beschreiben und vorhersagen — und welches der drei untersuchten Verfahren erzielt dabei die höchste Prognosegüte?

Die Daten

Sieben öffentlich zugängliche Quellen wurden zu einer Tabelle zusammengeführt — genauer zu zwei fast gleichen Analysedateien, einer je Frage. Eine Zeile dieser Tabelle ist *ein Stadtteil in einem Monat*.




Abbildung 2: Aus sieben Quellen — im Bild nach ihrer Herkunft zu fünf Gruppen zusammengefasst — entsteht eine Tabelle mit 4.752 Zeilen. Jede Zeile beschreibt einen Stadtteil in einem Monat durch zwölf Merkmale. Die beiden Fragezeichen sind das, was die Verfahren erraten sollen. Die dritte Zielgröße der Arbeit, die Einsätze je 1.000 Einwohner, ist dieselbe Zahl auf die Einwohner bezogen und dient als Gegenprobe. Die Beispielwerte in der rechten Box sind zur Veranschaulichung eingesetzt und stammen nicht aus der Arbeit.

Konkret umfasst der Bestand **36 der 41 Stadtteile** San Franciscos über **132 Monate** von Januar 2015 bis Dezember 2025. Die Feuerwehrquelle enthält insgesamt 720.258 Meldungen, davon 371.316 im Analysezeitraum. Die zwölf Merkmale verteilen sich auf drei inhaltliche Gruppen sowie zwei Hilfsgruppen:

GRUPPE	MERKMALE	ANZAHL
sozioökonomisch	Medianeinkommen, Armutsquote, Akademikerquote, Medianmiete, Leerstandsquote	5
kriminitätsbezogen	Kriminalitätsindex (logarithmiert)	1
baulich	Altbauanteil vor 1940, Wohngebäudeanteil, Risikogewerbeanteil (Flächenanteil von Einzelhandel und Unterhaltung sowie Produktion, Verteilung und Reparatur)	3
Größenkontrolle	Wohnbevölkerung (logarithmiert)	1
Saison	zwei Terme, die den Kalendermonat abbilden	2

Quelle: Tabelle 5 der Arbeit. Die Wohnbevölkerung dient als Größenkontrolle — ohne sie würde ein Modell vor allem abbilden, wie viele Menschen in einem Stadtteil wohnen, und nicht, wie dessen Struktur beschaffen ist.

Der Ablauf

Die Arbeit folgt einem etablierten Ablaufplan für Datenprojekte namens **CRISP-DM**. Der Name steht für „branchenübergreifender Standardprozess für Datenanalyse“ und beschreibt sechs Phasen. Die letzte Phase — der produktive Einsatz — entfällt in dieser Arbeit, weil kein Betrieb geplant ist.




Abbildung 3: Der Ablauf der Arbeit in drei Blöcken. Entscheidend ist, dass alle Festlegungen — Ziel, Maßstab, Merkmale, Aufteilung — getroffen wurden, *bevor* das erste Verfahren angepasst wurde. So lässt sich keine Entscheidung nachträglich auf ein gewünschtes Ergebnis hin verschieben.

Ein Punkt in diesem Ablauf verdient besondere Beachtung, weil er später das ganze Ergebnis prägt: **Wie wird geprüft, ob ein Modell wirklich etwas kann?**

Die Arbeit teilt nicht nach Zeit, sondern nach Ort. Sechs der 36 Stadtteile werden komplett zurückgehalten und erst ganz am Ende einmal angeschaut. Die übrigen 30 werden in fünf Gruppen zu je sechs Stadtteilen aufgeteilt; reihum ist eine Gruppe die Prüfgruppe und die anderen vier sind die Übungsgruppe. Das Ganze wird zehnmal mit neu gemischter Zuteilung wiederholt — zusammen 50 Rechenläufe je Verfahren.

Der Grund für die Trennung nach Stadtteilen statt nach Zeit: Ein Modell soll eine Aussage über einen Stadtteil treffen, den es *noch nie gesehen hat*. Würde man nach Zeit trennen, käme jeder Stadtteil sowohl in der Übung als auch in der Prüfung vor — das Modell könnte sein Niveau einfach auswendig lernen. Wie wirksam das wäre, zeigt eine Zahl aus der Arbeit: Allein der Mittelwert eines Stadtteils erklärt 92,5 % der Schwankung. Die Arbeit prüft bewusst die schwerere Aufgabe.

DIE WICHTIGSTE EINSCHRÄNKUNG, GLEICH VORWEG

4.752 Zeilen klingen nach viel. Aber die Monate eines Stadtteils ähneln einander stark: Die Zahl der Einsätze hängt weit mehr am Stadtteil als am Monat, und die Merkmale ändern sich kaum — drei von ihnen sind über den gesamten Zeitraum konstant. Die Arbeit rechnet aus der Ähnlichkeit der Einsatzzahlen aus, wie viel *unabhängige* Information tatsächlich vorliegt, und kommt auf rund **39 Einheiten statt 4.752**. Das ist der Grund, warum am Ende viele Unterschiede zwischen den Verfahren statistisch nicht absicherbar sind. Diese Grenze benennt die Arbeit selbst: Sie gilt für beide Fragestellungen, und belastbar ist unter ihr nur, was der gepaarte Vergleich zweier Verfahren trägt — nicht die bloße Rangfolge der Ergebnisse.

TEIL 2

Fachbegriffe, verständlich erklärt

Die wichtigsten Begriffe, die in den folgenden Teilen vorkommen — je eine kurze Erklärung und meist ein Beispiel aus dem Feuerwehr-Zusammenhang dieser Arbeit. Im weiteren Text sind Fachbegriffe beim ersten Auftreten *kursiv* gesetzt und führen als Link hierher zurück.

Die Aufgabe

Merkmal (englisch: Feature)

Eine Information über das, worum es geht — eine Spalte in der Tabelle.

HIER: Die Armutsquote eines Stadtteils ist ein Merkmal. Die Arbeit verwendet zwölf davon.

Zielgröße

Das, was vorhergesagt werden soll — die Spalte, die das Modell erraten muss.

HIER: Die Zahl der Einsätze und die überwiegende Einsatzart.

Regression

Eine Aufgabe, bei der eine *Zahl* herauskommen soll.

HIER: „Wie viele Einsätze?“ → 87. Bei einer Regression kann man fragen, um wie viel man danebenlag.

Klassifikation

Eine Aufgabe, bei der eine *Kategorie* herauskommen soll — eine von mehreren Schubladen.

HIER: „Welche Einsatzart überwiegt?“ → Fehllalarm. Hier gibt es kein „knapp daneben“: entweder richtig oder falsch.

Zählgröße

Eine Zahl, die durch Abzählen entsteht: 0, 1, 2, 3 ... nie negativ, nie halb.

HIER: Einsätze je Monat. Es gibt keine minus drei Einsätze — ein Verfahren, das so etwas vorhersagt, hat ein Problem.

Exposition / Offset

Eine Bezugsgröße, die man vorab herausrechnet, weil sie das Ergebnis trivialerweise größer macht.

HIER: Ein Stadtteil mit 40.000 Einwohnern hat mehr Einsätze als einer mit 4.000 — das ist kein Befund. Interessant ist die Zahl *je Einwohner*. Die Einwohnerzahl wird deshalb als Exposition mitgeführt.

Wie ein Modell lernt und geprüft wird

Trainingsdaten und Testdaten

Die Übungsaufgaben und die Klausur. Auf den Trainingsdaten sucht sich das Modell seine Regeln; auf den Testdaten wird gemessen, ob sie taugen.

HIER: 24 Stadtteile zum Üben, 6 zum Prüfen — und zwar *ganze* Stadtteile, damit das Modell keinen davon schon kennt.

Kreuzvalidierung

Man macht die Klausur nicht einmal, sondern reihum mit wechselnden Prüfgruppen, und mittelt die Ergebnisse.

HIER: Fünf Gruppen zu je sechs Stadtteilen, jede einmal Prüfgruppe; das Ganze zehnmal neu gemischt — 50 Läufe je Verfahren.

Hold-out / Schlussbewertung

Ein Datenteil, der während der gesamten Entwicklung *ungeöffnet* bleibt und ganz am Ende genau einmal geöffnet wird.

HIER: Sechs Stadtteile. Sie dienen als letzte Probe — man kann nichts mehr nachbessern, ohne zu schummeln.

Baseline (Vergleichsmaßstab)

Ein bewusst einfaches Modell, das die gleiche Aufgabe löst. Wer aufwendiger rechnet, muss es schlagen — sonst hat der Aufwand nichts gebracht.

HIER: Zwei Stufen. Stufe 1 ist stumpf („immer den Durchschnitt sagen“ bzw. „immer die häufigste Einsatzart“), Stufe 2 ist ein schlichtes statistisches Modell. Maßgeblich ist Stufe 2.

Overfitting (Überanpassung)

Ein Modell lernt die Übungsaufgaben auswendig, samt aller Zufälle darin — und versagt bei neuen Aufgaben.

HIER: XGBoost erreicht auf den Übungsdaten ein Bestimmtheitsmaß von 0,975, auf neuen Stadtteilen nur 0,486. Eine solche Lücke ist das typische Anzeichen von Überanpassung.

Underfitting (Unteranpassung)

Das Gegenteil: Das Modell ist zu starr und liegt schon bei den Übungsaufgaben daneben.

Verzerrung und Streuung (Bias und Varianz)

Zwei Fehlerarten. Verzerrung heißt: das Modell zielt systematisch daneben. Streuung heißt: es zielt mal so, mal so.

HIER: Wie bei einer Dartscheibe — alle Pfeile dicht beieinander, aber links unten (Verzerrung), oder rund um die Mitte verstreut (Streuung). Beide tragen zum Gesamtfehler bei, und sie lassen sich nicht gleichzeitig beliebig klein machen.

Regularisierung

Eine eingebaute Bremse, die ein Modell daran hindert, zu wild auf die Übungsdaten zu reagieren.

HIER: Die Ridge Regression darf ihre Stellschrauben nicht beliebig weit aufdrehen — große Werte kosten sie Punkte.

Hyperparameter

Einstellungen, die man *vorher* festlegen muss, weil das Modell sie nicht selbst aus den Daten lernen kann.

HIER: „Wie viele Bäume?“, „wie tief?“, „wie stark bremsen?“. Die Arbeit probiert je Suchlauf 100 zufällige Kombinationen aus. Die beiden Baselines haben keine einzige solche Einstellung — das ist Absicht.

Verlustfunktion

Die Rechenvorschrift, die dem Modell sagt, wie schlimm ein bestimmter Fehler ist. Das Modell sucht die Einstellung, bei der dieser Wert am kleinsten ist.

HIER: Wenn große Ausreißer besonders wehtun sollen, quadriert man die Abweichungen — dann zählt ein Fehler von 10 nicht doppelt, sondern vierfach gegenüber einem Fehler von 5.

Koeffizient

Eine Zahl, die angibt, wie stark ein Merkmal ins Gewicht fällt — das Gewicht auf einer Stellschraube.

HIER: Ein positiver Koeffizient bei der Armutsquote heißt: höhere Armut, mehr erwartete Einsätze.

Wie Ergebnisse abgesichert werden

p-Wert und Signifikanz

Der p-Wert beantwortet: „Wenn zwischen den beiden Verfahren in Wahrheit gar kein Unterschied bestünde — wie oft würde der Zufall allein einen mindestens so großen Unterschied hervorbringen?“ Ist das selten (üblich: unter 5 %, also $p < 0,05$), nennt man das Ergebnis *signifikant*.

HIER: Ridge liegt vor XGBoost mit $p = 0,012$ (nach Holm für sechs gleichzeitige Vergleiche korrigiert) — das ist absicherbar. Ridge liegt vor der Baseline mit $p = 0,275$ — das ist es nicht.

Was „nicht signifikant“ *nicht* heißt

Es heißt nicht „die beiden sind gleich gut“. Es heißt nur: Mit diesen Daten lässt sich ein Unterschied nicht nachweisen. Das kann auch daran liegen, dass zu wenige unabhängige Daten vorliegen.

HIER: Genau das ist der Fall — getestet wird auf nur zehn Vergleichspaaren, und bei Unterschieden in der Größe, wie sie hier gegen die Baseline gemessen wurden, schlägt der verwendete Test je nach Vergleich nur in 8 bis 40 % der Fälle an. Die Arbeit rechnet das eigens nach.

Konfidenzintervall

Ein Bereich statt einer einzelnen Zahl: „der wahre Wert liegt plausibel irgendwo hier drin“. Enthält der Bereich die Null, ist auch „gar kein Unterschied“ plausibel.

HIER: Ridge gegen die Baseline: +2,06 mit Bereich von -0,76 bis +4,88. Die Null liegt drin — also ist auch denkbar, dass Ridge gar nicht besser ist.

Effektstärke

Wie groß ein Unterschied ist, gemessen in Vielfachen der üblichen Schwankung. Ein großer Unterschied in einem ruhigen Feld fällt auf; derselbe Unterschied in einem unruhigen Feld geht unter.

Die Bewertungsmaße dieser Arbeit

RMSE (Wurzel des mittleren quadratischen Fehlers)

Der typische Abstand zwischen Vorhersage und Wirklichkeit, wobei große Ausreißer besonders schwer wiegen. **Kleiner ist besser.**

HIER: RMSE 30 heißt grob: Die Vorhersage liegt typischerweise um etwa 30 Einsätze daneben. Die Einheit ist dieselbe wie bei der Zielgröße — Einsätze.

MAE (mittlerer absoluter Fehler)

Der durchschnittliche Abstand, ohne Extra-Bestrafung für Ausreißer. **Kleiner ist besser.**

HIER: MAE 20 heißt: im Schnitt 20 Einsätze daneben. Der MAE ist nie größer als der RMSE; ist der Abstand groß, gibt es einzelne heftige Fehlschläge.

R² (Bestimmtheitsmaß)

Wie viel der tatsächlichen Schwankung das Modell erklärt. 1,0 wäre perfekt, 0 wäre so gut wie „immer den Durchschnitt sagen“. **Größer ist besser — und negativ ist möglich:** dann ist das Modell schlechter als der Durchschnitt.

HIER: Der Gesamtmittelwert erreicht -0,865: Der Durchschnitt der Übungsstadtteile liegt bei den unbekannten Stadtteilen weiter daneben, als es deren eigener Durchschnitt täte.

Macro-F1

Ein Maß für Klassifikation, das *jede Kategorie gleich schwer* wiegt — auch die seltene. 1,0 wäre perfekt. **Größer ist besser.**

HIER: Unverzichtbar, weil 79,6 % aller Stadtteil-Monate von Fehlalarmen dominiert werden. Wer stur „Fehlalarm“ sagt, läge in rund 80 % der Fälle richtig (in der Kreuzvalidierung 79,5 %) — und hätte nichts gelernt. Beim Macro-F1 bekäme er nur 0,221.

Macro-AUROC

Misst, ob das Modell die richtige *Rangfolge* trifft — ob es bei einem echten Brandmonat wenigstens eine höhere Brandwahrscheinlichkeit ausgibt als bei einem anderen. 0,5 wäre Münzwurf, 1,0 perfekt.

HIER: Ein Modell kann die Klassen gut trennen und sie trotzdem falsch zuordnen — genau das passiert in der Arbeit auf den sechs zurückgehaltenen Stadtteilen.

Accuracy (Trefferquote)

Der schlichte Anteil richtiger Zuordnungen. In dieser Arbeit nur mitgeführt, nicht maßgeblich — aus dem beim Macro-F1 genannten Grund.

Zwei Begriffe für den Schluss

Attribution

Die Frage: Worauf achtet ein fertiges Modell am meisten?

HIER: Beim Random Forest der Einsatzart nutzt die Arbeit dafür das Verfahren SHAP, das jede einzelne Vorhersage auf die beteiligten Merkmale verteilt; beim Poisson-Modell der Einsatzzahl die Beträge seiner standardisierten Koeffizienten.

Ablation

Die andere Frage: Was passiert, wenn man eine Merkmalsgruppe komplett weglässt und neu rechnet?

HIER: Beide Fragen können gegensätzliche Antworten geben — und in dieser Arbeit tun sie es. Worauf ein Modell schaut, ist nicht dasselbe wie das, was es braucht.

TEIL 3

Wie die fünf Verfahren funktionieren

Fünf Verfahren treten an, und sie sind nicht gleichberechtigt. Drei davon werden untersucht (Ridge Regression, Random Forest, XGBoost), zwei sind der Maßstab, an dem sie sich messen lassen müssen (Poisson-GLM und multinomiales Logit). Die Logik dahinter ist streng: **Wenn ein aufwendiges Verfahren die Aufgabe nicht besser löst als ein schlichtes, rechtfertigt es seinen Aufwand nicht.**

Nicht jedes Verfahren tritt bei jeder Frage an. Bei der Frage nach der *Anzahl* laufen alle drei untersuchten Verfahren gegen das Poisson-Modell. Bei der Frage nach der *Art* treten nur Random Forest und XGBoost gegen das Logit an. Die Ridge Regression fällt dort aus: Auf Kategorien angewendet, lieferte sie Werte unter null oder über eins, also keine Wahrscheinlichkeiten — und das passende lineare Verfahren für Kategorien ist bereits der Maßstab, das Logit.

1. Ridge Regression


DIE GRUNDIDEE

Stellen Sie sich ein Mischpult mit zwölf Reglern vor — einer je *Merkmal*. Wie weit jeder Regler aufgedreht wird, bestimmt, wie stark dieses Merkmal in die Vorhersage eingeht. Das Gerät sucht die Reglerstellung, bei der die Vorhersage im Schnitt am wenigsten danebenliegt. Das ist eine ganz gewöhnliche lineare Rechnung: alle Merkmale werden gewichtet und aufaddiert.

Das Besondere an Ridge ist eine **Bremse**. Wenn zwei Regler das Gleiche bewirken — etwa weil Medianeinkommen und Medianmiete fast dasselbe messen —, kann die gewöhnliche Rechnung den einen weit nach oben und den anderen weit nach unten drehen und trotzdem dasselbe Ergebnis liefern. Solche Einstellungen sind extrem wacklig: Eine kleine Änderung in den Daten kippt sie komplett. Ridge verlangt deshalb für jede Reglerbewegung einen Aufpreis. Weit aufgedrehte Regler kosten Punkte, und deshalb bleiben alle Regler nah an der Null, wenn es nicht zwingende Gründe gibt. Das nennt man *Regularisierung*.

OHNE BREMSE


Regler schlagen wild aus, gleichen sich gegenseitig aus



kippt bei kleinsten Datenänderungen

MIT BREMSE (RIDGE)

jeder Ausschlag kostet — alle bleiben nah an null



bleibt stabil, auch bei ähnlichen Merkmalen

Abbildung 4: Jeder Balken ist ein Regler für ein Merkmal; die waagerechte Linie ist die Nullstellung. Links die gewöhnliche Rechnung, rechts Ridge. Ridge nimmt eine kleine Verzerrung in Kauf und bekommt dafür weniger schwankende Vorhersagen; bei kleinem Strafgewicht sinkt die Schwankung schneller, als die Verzerrung wächst.

WARUM DAS HIER SINNVOLL IST

Die Merkmale dieser Arbeit beschreiben einander stärker als sie die Zielgröße beschreiben. Der größte Zusammenhang in der Merkmalstabelle liegt bei 0,921 zwischen Medianeinkommen und Medianmiete — das sind fast Zwillinge. Genau in dieser Lage wird die gewöhnliche Rechnung instabil, und genau dafür ist Ridge gebaut.

2. Random Forest

DIE GRUNDIDEE

Ein **Entscheidungsbaum** ist eine Kette von Ja/Nein-Fragen: „Liegt die Armutsquote über 0,15? Wenn ja: Liegt der Altbauanteil über 0,6? Wenn ja: sage 120 Einsätze vorher.“ Ein einzelner Baum ist gut darin, Zusammenspiele zwischen Merkmalen zu finden, aber er ist launisch: Ein paar andere Übungsdaten, und er stellt völlig andere Fragen.

Der Random Forest löst das wie ein Publikumsjoker. Er baut nicht einen Baum, sondern hunderte — jeden auf einer Zufallsstichprobe der Übungsdaten, gezogen mit Zurücklegen (manche Zeilen kommen darin mehrfach vor, andere gar nicht), und jeden mit einer zufällig eingeschränkten Auswahl an Merkmalen je Frage. Dadurch werden die Bäume *unterschiedlich*. Am Ende wird gemittelt. Einzelne Irrtümer gleichen sich dabei aus, und was übrig bleibt, ist deutlich stabiler als jeder Baum für sich.

VIELE BÄUME, GLEICHZEITIG GEWACHSEN — JEDER SIEHT ANDERE DATEN




Abbildung 5: Jeder Baum ist für sich unzuverlässig, aber die Fehler zeigen in verschiedene Richtungen und heben sich beim Mitteln weitgehend auf. Die Zahlen sind ein erfundenes Beispiel zur Veranschaulichung des Prinzips.

WARUM DAS HIER SINNVOLL IST

Bäume finden Zusammenspiele von selbst. Ein lineares Modell rechnet jedes Merkmal einzeln dazu; wenn Armut nur *in Kombination mit* Altbaubestand wirkt, muss man ihm das ausdrücklich sagen — wer es nicht vorab vermutet, findet es auch nicht. Ein Baum findet solche Kombinationen, ohne dass man sie vorher kennen muss. Das ist der Vorsprung, den die Baumverfahren in dieser Arbeit haben könnten. Ob sie ihn hier tatsächlich haben, ist genau die empirische Frage der Arbeit.

3. XGBoost

DIE GRUNDIDEE

XGBoost verwendet ebenfalls Bäume, aber baut sie in umgekehrter Logik. Beim Random Forest wachsen alle Bäume gleichzeitig und unabhängig. Bei XGBoost wachsen sie **nacheinander**, und jeder neue Baum bekommt eine andere Aufgabe: Er soll nicht die Einsätze vorhersagen, sondern genau das, was die bisherigen Bäume noch falsch hatten. Das ist ein schrittweises Nachbessern und heißt *Boosting*.

Ein Vergleich: Der Random Forest ist eine Jury, die unabhängig voneinander schätzt und dann mittelt. XGBoost ist ein Team, bei dem jeder Nachfolger die Notizen des Vorgängers liest und nur dessen Restfehler bearbeitet.

Dieses Verfahren neigt naturgemäß zum Auswendiglernen — irgendwann korrigiert es nur noch Zufälle in den Übungsdaten. Deshalb hat auch XGBoost eine *Bremse*: Jeder neue Baum darf nur einen kleinen Teil seiner Korrektur beisteuern, seine Tiefe ist begrenzt, und große Werte in seinen Endknoten kosten Strafpunkte.

EIN BAUM NACH DEM ANDEREN — JEDER BEARBEITET NUR DEN RESTFEHLER




Abbildung 6: Der Restfehler schrumpft mit jedem weiteren Baum. Der Reiz des Verfahrens ist auch seine Gefahr: Ohne Bremse schrumpft der Fehler bei den Übungsdaten weiter, während er bei neuen Daten schon wieder wächst. Die Balkenhöhen stellen das Prinzip dar und sind keine gemessenen Werte.

WARUM DAS HIER SINNVOLL IST

In den Vergleichsstudien, die die Arbeit zitiert, liegen Baumverfahren auf Daten in Tabellenform meist vorn, und XGBoost übertraf dort neuronale Netze überwiegend. Es ist damit der natürliche Herausforderer. Allerdings arbeiten diese Studien mit unabhängigen Beobachtungen; ob ihre Rangfolge auch hält, wenn ganze Stadtteile unbekannt bleiben, prüfen sie nicht — genau hier setzt die Arbeit an.

4. Poisson-GLM — die Baseline für die Anzahl


DIE GRUNDIDEE

Dieses Modell ist von Grund auf für eine Eigenschaft der Zielgröße gebaut: Sie ist eine *Zählgröße*. Man kann keine minus fünf Einsätze haben, und bei Zählungen hängen Höhe und Schwankung zusammen — wo im Schnitt 200 Einsätze passieren, schwankt es stärker als dort, wo es zehn sind.

Die Denkweise des Modells ist **multiplikativ**: Es schätzt nicht direkt die Zahl der Einsätze, sondern das *Risiko pro Einwohner*, und multipliziert das anschließend mit der Einwohnerzahl. Die Merkmale wirken dabei

als Faktoren, nicht als Summanden — ein Merkmal erhöht die erwartete Zahl also um einen bestimmten Prozentsatz und nicht um eine feste Anzahl.

DIE GRÖSSE WIRD HERAUSGERECHNET, BEVOR DIE STRUKTUR BEURTEILT WIRD



Das Modell multipliziert, statt zu addieren. Deshalb kann nie eine negative Zahl herauskommen — anders als bei einer geraden Linie.

Abbildung 7: Das Poisson-Modell mit Exposition. Es rechnet die Einwohnerzahl als Bezugsgröße heraus und trennt so, was ein Stadtteil an Einsätzen allein deshalb hat, weil dort viele Menschen wohnen, von dem, was seine Struktur hervorbringt. Ganz sauber gelingt das nach der Arbeit nicht: Wo tagsüber viele Pendler und Besucher sind, wie in der Innenstadt, bildet die Wohnbevölkerung die tatsächliche Last nur unvollständig ab.

WARUM DAS ALS MASSSTAB DIENT

Genau weil es so schlicht ist. Es hat **keinen einzigen einstellbaren Hyperparameter** — man kann bei ihm nichts optimieren, nichts glücklich treffen und nichts versehentlich gut einstellen. Es liefert jedes Mal dasselbe Ergebnis. Das macht es zu einer ehrlichen Messlatte: Wer es nicht schlägt, hat mit all seinen Einstellungen und seiner Rechenzeit nichts gewonnen. Die Arbeit lässt es zudem über genau dieselben 50 Durchläufe und dieselben zwölf Merkmale laufen wie die Herausforderer — es ist ein vollwertiger Mitbewerber, kein bequemer Strohhalm.

5. Multinomiales Logit — die Baseline für die Einsatzart

DIE GRUNDIDEE

Bei der Frage nach der Einsatzart gibt es vier mögliche Antworten. Das Modell gibt deshalb nicht eine Antwort aus, sondern vier Wahrscheinlichkeiten, die sich zu 100 % addieren. Vorhergesagt wird die Kategorie mit dem höchsten Wert.

Technisch funktioniert es über **Chancenverhältnisse**: Eine Kategorie wird als Bezugspunkt gewählt, und für jede der übrigen wird geschätzt, um welchen Faktor sie gegenüber diesem Bezugspunkt wahrscheinlicher oder unwahrscheinlicher wird, wenn sich ein Merkmal ändert. Aus diesen Verhältnissen lassen sich alle vier Wahrscheinlichkeiten zurückrechnen.

EINGABE: DIE 12 MERKMALE

Armutsquote
Altbauanteil
Kriminalitätsindex
Einwohnerzahl
Jahreszeit
...

Modell →

AUSGABE: VIER WAHRSCHEINLICHKEITEN, ZUSAMMEN 100 %

Fehlalarm		62 %
technische Hilfe		23 %
Rettungsdienst		10 %
Brand		5 %

Vorhergesagt wird die höchste: Fehlalarm

Abbildung 8: Das Logit-Modell verteilt 100 % auf die vier Einsatzarten. Die Prozentwerte im Bild sind erfunden und dienen nur der Darstellung des Prinzips.

WARUM DAS ALS MASSSTAB DIENT

Aus demselben Grund wie beim Poisson-Modell: Es hat keine einstellbaren Schrauben und ist damit reproduzierbar und unbestechlich. Ein zusätzlicher Kniff der Arbeit: Weil Fehlalarme 79,6 % aller Fälle ausmachen und Brände nur 1,5 %, würde das Modell ohne Ausgleich vor allem die häufigste Klasse lernen. Es bekommt deshalb *ausgeglichene Klassengewichte*: Ein seltener Brandmonat zählt beim Lernen entsprechend schwerer. Die Daten selbst werden dabei nicht verändert — keine Zeile wird verdoppelt oder entfernt.

TEIL 4

Die Formeln, Stück für Stück

Formeln sind abgekürzte Sätze. Dieser Teil schreibt sie wieder aus. Verständlichkeit geht dabei vor mathematischer Vollständigkeit — wo bewusst vereinfacht wurde, steht es dabei.

VIER ZEICHEN, DIE ÜBERALL VORKOMMEN

Σ (griechisches Sigma) heißt schlicht „*addiere alles zusammen*“. Unter dem Zeichen steht, wo man anfängt, darüber, wo man aufhört. „ Σ über alle Zeilen“ heißt: gehe jede Zeile der Tabelle durch und zähle die Werte zusammen.

Ein Dach über einem Buchstaben (β , $\hat{y}$) bedeutet *geschätzt* — das ist nicht der wahre Wert, sondern der, den das Modell aus den Daten gewonnen hat.

Fette Buchstaben ($\mathbf{x}$, $\boldsymbol{\beta}$) sind keine einzelne Zahl, sondern eine ganze Liste von Zahlen — hier meist eine Liste mit zwölf Einträgen, einem je Merkmal.

„**arg min**“ heißt: *diejenige Einstellung, bei der der folgende Ausdruck am kleinsten wird*. Es ist die mathematische Form von „suche das Beste“.

Die gemeinsame Grundform der beiden Baselines

Beide Baselines gehören zur selben Modellfamilie, den *verallgemeinerten linearen Modellen*. Ihre allgemeine Form ist Formel 1 der Arbeit:

$$g(\mathbb{E}[y | \mathbf{x}]) = \mathbf{x}^T \boldsymbol{\beta}$$

Formel 1 der Arbeit · allgemeine Form eines verallgemeinerten linearen Modells

$\mathbb{E}[y | \mathbf{x}]$ Der **Erwartungswert**: Was kommt im Schnitt heraus, wenn ein Stadtteil-Monat die Merkmale $\mathbf{x}$ hat? Der senkrechte Strich heißt „gegeben, dass“. Also: der erwartete Wert, gegeben diese Merkmale.

$\mathbf{x}^T \boldsymbol{\beta}$ Die **gewichtete Summe**: Nimm jedes Merkmal, multipliziere es mit seinem *Koeffizienten*, und addiere alles. Ausgeschrieben: $\beta_1 \cdot \text{Armutsquote} + \beta_2 \cdot \text{Altbauanteil} + \dots$ Das kleine hochgestellte Zeichen T („transponiert“) gehört nur zur Schreibweise dieser Rechnung.

$g(\dots)$ Die **Verbindungsfunktion**. Sie ist der ganze Trick dieser Modellfamilie: Die gewichtete Summe kann jeden Wert annehmen, auch negative. Eine Einsatzzahl darf aber nicht negativ sein und eine Wahrscheinlichkeit muss zwischen 0 und 1 liegen. g rechnet zwischen beiden Welten um.

Formel 2a · Poisson-GLM mit Exposition

$$\log(\mu) = \log(B) + \mathbf{x}^T \boldsymbol{\beta}$$

Formel 2a der Arbeit · Baseline für die Einsatzhäufigkeit

- μ** Die **erwartete Zahl der Einsätze** in diesem Stadtteil-Monat — das, was gesucht wird.
- log** Der **Logarithmus**. Hier reicht eine einzige Eigenschaft davon: Was auf der Logarithmus-Seite addiert wird, wird auf der normalen Seite *multipliziert*. Deshalb ist dieses Modell multiplikativ, so wie es Abbildung 7 gezeigt hat.
- B** Die **Wohnbevölkerung** des Stadtteils, die *Exposition*.
- log(B)** Steht **ohne eigenen Koeffizienten** da — oder genauer: mit einem fest auf eins gesetzten. Das Modell darf hier nichts justieren. Genau das macht aus einer Aussage über Häufigkeiten eine Aussage über Raten, ohne dass dafür ein Freiheitsgrad verbraucht wird. Ein solcher fest vorgegebener Term heißt *Offset*.

Ausgeschrieben lautet die Formel: *Die erwartete Einsatzzahl ist die Einwohnerzahl, multipliziert mit einem Risikofaktor, der sich aus den Merkmalen des Stadtteils ergibt.*

Formel 3 • Multinomiales Logit

$$\log \frac{\Pr(y = k \mid \mathbf{x})}{\Pr(y = K \mid \mathbf{x})} = \mathbf{x}^\top \boldsymbol{\beta}_k$$

Formel 3 der Arbeit • Baseline für die Einsatzart

- Pr(...)** Eine **Wahrscheinlichkeit**, also eine Zahl zwischen 0 und 1.
- k** Eine der Einsatzarten, zum Beispiel „Brand“.
- K** Die **Bezugskategorie**, mit der alle anderen verglichen werden. Welche das ist, ist reine Konvention und ändert am Ergebnis nichts.
- der Bruch** Das **Chancenverhältnis**: Wie viel mal wahrscheinlicher ist „Brand“ als die Bezugskategorie? Steht dort 2, ist Brand doppelt so wahrscheinlich.
- β_k** Jede Kategorie hat ihren **eigenen Satz Koeffizienten**. Bei vier Kategorien werden drei solche Sätze geschätzt; die Bezugskategorie braucht keinen eigenen, ihre Wahrscheinlichkeit ergibt sich daraus, dass sich alle zu eins addieren müssen.

Formel 4 • Ridge Regression

$$\boldsymbol{\beta} = \arg \min_{\boldsymbol{\beta}} \{ \sum_i (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \lambda \sum_j \beta_j^2 \}$$

Formel 4 der Arbeit • Zielfunktion der Ridge Regression

Diese Formel ist der Kern des ganzen Verfahrens, und sie besteht aus genau zwei Bestandteilen, die miteinander im Streit liegen.

- y_i** Der **wirklich beobachtete** Wert der Zielgröße in Zeile i.
- x_i[⊤]β** Der **vorhergesagte** Wert für dieselbe Zeile.
- (...)²** Die Differenz wird **quadriert**. Zwei Gründe: Erstens verschwindet damit das Vorzeichen — zu hoch und zu niedrig sind gleich schlimm. Zweitens wiegen große Fehler überproportional schwer: 20 danebenzuliegen ist nicht doppelt, sondern viermal so teuer wie 10.

- Σ_i Summiert über **alle Zeilen** der Trainingsdaten. Dieser erste Block ist die klassische [Verlustfunktion](#): Wie schlecht passt das Modell?
- $\lambda \Sigma_j \beta_j^2$ Der **Strafterm** — der zweite Block, und alles, was Ridge von der gewöhnlichen Rechnung unterscheidet. Summiert wird hier über die *Koeffizienten*, nicht über die Zeilen. Jeder Regler, der weit von null entfernt steht, erhöht den Wert und macht die Lösung damit schlechter.
- λ Das **Strafgewicht** (griechisch: Lambda): wie hart die Bremse zieht. Bei $\lambda = 0$ verschwindet der Strafterm, und man hat wieder die gewöhnliche Rechnung. Je größer λ , desto näher rücken alle Koeffizienten an null. λ ist der einzige [Hyperparameter](#) der Ridge Regression — und damit genau der eine Parameter, den die Baseline nicht kennt.

Ausgeschrieben: *Suche die Reglerstellung, bei der die Summe aus zwei Übeln am kleinsten ist — wie sehr man danebenliegt, und wie weit man die Regler dafür aufreißen musste.*

Die Arbeit gibt zusätzlich die geschlossene Lösung an (Formel 4a). Sie besagt, dass man das Ergebnis direkt ausrechnen kann und nichts ausprobieren muss:

$$\beta = (X^T X + \lambda I)^{-1} X^T y$$

Formel 4a der Arbeit · geschlossene Lösung

Bewusst vereinfacht: Die Einzelheiten dieser Formel sind Matrizenrechnung und werden hier nicht auseinandergenommen. Eine Sache lohnt aber: Das hochgestellte -1 steht für eine Umkehroperation, ähnlich dem Teilen bei gewöhnlichen Zahlen. Und wie man durch null nicht teilen kann, kann diese Umkehrung scheitern oder sehr wacklig werden, wenn Merkmale einander (fast) vollständig beschreiben. Das λ addiert einen positiven Wert an der entscheidenden Stelle und macht die Rechnung dadurch auch dann durchführbar. Der Strafterm ist also nicht nur eine Bremse gegen [Overfitting](#), sondern hält die Rechnung auch bei sehr ähnlichen Merkmalen stabil.

Formel 5 · XGBoost

$$\mathcal{L} = \Sigma_i l(y_i, \hat{y}_i) + \Sigma_r \Omega(f_r)$$

Formel 5 der Arbeit · regularisierte Zielfunktion des Gradient Boosting

- $\mathcal{L}$ Die **Gesamtzielgröße**, die XGBoost so klein wie möglich machen will.
- $l(y, \hat{y})$ Die **Verlustfunktion** für eine einzelne Zeile: Wie weit lag die Vorhersage $\hat{y}$ neben der Wirklichkeit y ?
 - Σ_i Summiert über alle Zeilen — der gesamte Anpassungsfehler.
 - f_r Der **r-te Baum** des Modells.
- $\Omega(f_r)$ Der **Strafterm für die Komplexität** dieses Baums — er wächst mit der Zahl der Endknoten (Gewicht γ) und der Größe der dort abgelegten Werte (Gewicht λ). In der Arbeit wird nur λ gesucht; γ bleibt null, die Zahl der Endknoten kostet hier also nichts extra.
- Σ_r Summiert über **alle Bäume**.

Die Ähnlichkeit zur Ridge-Formel ist kein Zufall, und sie ist der wichtigste Punkt dieses Abschnitts: **Beide Formeln haben denselben Bauplan** — links steht, wie schlecht das Modell passt, rechts steht, was seine

Flexibilität kosten soll. Nur der Preis wird verschieden berechnet: Ridge bestraft große Regler, XGBoost große Werte in den Endknoten seiner Bäume. Dieselbe Idee, zweimal.

Random Forest · ohne eigene Formel

IN DER ARBEIT STEHT HIER KEINE FORMEL

Die Arbeit führt im Formelverzeichnis neun Formeln auf (1 bis 7, dazu 2a und 4a); für den Random Forest ist keine darunter; die Arbeit beschreibt ihn in Worten. Als Formel wäre ein Baum nur eine lange Fallunterscheidung aus Ja/Nein-Fragen **ZUSATZ**. Knapp angeben lässt sich der letzte Schritt: Alle Bäume sagen etwas vorher, und ihre Vorhersagen werden gemittelt — bei einer Zahl der Durchschnitt, bei einer Kategorie die mit der höchsten gemittelten Wahrscheinlichkeit **ZUSATZ**. Genau das zeigt Abbildung 5 in Teil 3.

Die Arbeit nennt dafür allerdings ein wichtiges Ergebnis aus der Literatur: Der Fehler eines solchen Waldes hängt von zwei Dingen ab — wie treffsicher die einzelnen Bäume sind und wie stark sie einander ähneln. Deshalb wird jedem Baum an jedem Verzweigungspunkt nur eine zufällige Auswahl der Merkmale angeboten: Das macht die Bäume einander unähnlicher, und ihr Mittelwert streut weniger — auch wenn der einzelne Baum dabei etwas an Treffsicherheit verlieren kann **ZUSATZ**.

Formel 6 · Das Macro-F1-Maß

$$F1_k = \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \quad \text{Macro-F1} = \frac{1}{K} \sum_k F1_k$$

Formel 6 der Arbeit · klassenweises F1-Maß und Macro-F1

P_k **Präzision:** Von allen Monaten, die das Modell als „Brand“ bezeichnet hat — wie viele waren es wirklich? (Wie oft hat es sich nicht blamiert, wenn es Alarm schlug?)

R_k **Trefferquote:** Von allen Monaten, die wirklich Brandmonate waren — wie viele hat das Modell gefunden? (Wie viel hat es übersehen?)

F1_k Beide zusammen, als **harmonisches Mittel**. Anders als ein gewöhnlicher Durchschnitt fällt dieses Mittel niedrig aus, sobald auch nur einer der beiden Werte niedrig ist. Beide Werte müssen gut sein — einer allein reicht nicht.

K Die Zahl der Kategorien, hier vier.

(1/K) Σ_k Der **ungewichtete Durchschnitt** über alle vier Kategorien — darin steckt das Wort „Macro“. Die seltene Kategorie „Brand“ zählt genauso viel wie die häufige Kategorie „Fehlalarm“, obwohl sie rund fünfzigmal seltener vorkommt.

Diese letzte Zeile hat für die Ergebnisse dieser Arbeit spürbare Folgen, und sie wird in Teil 5 wieder auftauchen: Weil „Brand“ ein volles Viertel des Gesamtwerts ausmacht, obwohl es kaum vorkommt, hängt ein Viertel des Leitmaßes an sehr wenigen Fällen.

Warum die Arbeit trotzdem dieses Maß wählt: Ein Maß, das jede Kategorie nach ihrer Häufigkeit gewichtet, würde die seltenen Kategorien praktisch ignorieren — darunter die Brände, die zu den folgenschwersten Einsätzen gehören **ZUSATZ**.

TEIL 5

Bewertung und Ergebnisse

Jetzt die Zahlen. Alle Werte in diesem Teil stammen aus den Ergebnistabellen und dem Text der Arbeit; nichts ist geschätzt oder ergänzt. Gerundet sind nur einzelne Werte, etwa in Abbildung 12 und bei den Korrelationen; eigene Nachrechnungen sind markiert.

Womit gemessen wird

Für die beiden Fragen gelten verschiedene Maße, weil eine Zahl anders danebenliegen kann als eine Kategorie.

MASS	WOFÜR	WAS DIE ZAHL BEDEUTET	BESSER IST
RMSE	Anzahl	typischer Abstand zur Wirklichkeit, in Einsätzen; große Ausreißer wiegen extra schwer	kleiner
MAE	Anzahl	durchschnittlicher Abstand, in Einsätzen, ohne Extra-Strafe	kleiner
R²	Anzahl	Anteil der erklärten Schwankung; 0 = so gut wie der Durchschnitt	größer
Macro-F1	Einsatzart	Trefferqualität, jede der vier Arten gleich gewichtet	größer
Macro-AUROC	Einsatzart	ob die Rangfolge der Wahrscheinlichkeiten stimmt; 0,5 = Münzwurf	größer

Hauptmaße sind laut Arbeit der RMSE bei der Anzahl und das Macro-F1 bei der Einsatzart; die übrigen laufen ergänzend mit. Die Accuracy wird nur mitgeführt und ist nicht maßgeblich.

ZWEI AUSWERTUNGEN, NICHT EINE

Jedes Ergebnis liegt in zwei Fassungen vor, und beide werden berichtet:

Kreuzvalidierung — 50 Durchläufe auf 30 Stadtteilen, jeweils mit wechselnden Prüfgruppen. Nur hier gibt es eine Streuung und einen statistischen Test.

Schlussbewertung — eine einzige Messung auf den sechs zurückgehaltenen Stadtteilen, nachdem jedes Verfahren auf allen 30 übrigen neu angepasst wurde. Ohne Streuung, ohne Test. Die Arbeit hält ausdrücklich fest, dass diese sechs Stadtteile kein verkleinertes Abbild der Stadt sind: Auf sie entfallen 4,67 % branddominierte Monate gegenüber 0,83 % bei den übrigen. Sie sind eine Probe auf einer anders zusammengesetzten Auswahl, kein Durchschnitt.

Ergebnis 1 · Die Zahl der Einsätze

MODELL	KREUZVALIDIERUNG			SCHLUSSBEWERTUNG		
	RMSE	MAE	R ²	RMSE	MAE	R ²
Poisson-GLM (Baseline)	32,99	21,44	0,607	28,46	20,10	0,625
Ridge Regression	30,93	20,36	0,655	30,30	21,95	0,575
Random Forest	34,96	24,07	0,498	27,46	21,13	0,651
XGBoost	37,39	25,13	0,486	25,83	19,86	0,691
Gesamtmittelwert (Stufe 1)	68,08	50,34	-0,865	49,32	38,70	-0,126

Tabelle 9 der Arbeit. Fett hervorgehoben ist jeweils der beste Wert je Spalte. Man beachte: In der linken Hälfte gewinnt Ridge, in der rechten XGBoost — die Rangfolge dreht sich um.




Abbildung 9: Derselbe Datensatz, zwei Auswertungen, zwei Sieger. Was in beiden Auswertungen gleich bleibt: Alle vier Modelle liegen weit vor dem stumpfen Durchschnitt, und sie liegen alle nah beieinander. Die Balkenlängen entsprechen den RMSE-Werten aus Tabelle 9 der Arbeit.

WAS DAS BEDEUTET

Erstens: Die Merkmale tragen. Der stumpfe Gesamtdurchschnitt kommt auf einen RMSE von 68,08 und ein R² von -0,865 — er liegt bei unbekannten Stadtteilen weiter daneben, als es deren eigener Durchschnitt täte. Jedes Modell, das die zwölf Merkmale nutzt, halbiert diesen Fehler ungefähr. Ein Stadtteil, den das Modell noch nie gesehen hat, lässt sich also aus seinem Profil einschätzen. Die Arbeit beziffert die praktische Genauigkeit auf einen mittleren absoluten Fehler von rund 20 Einsätzen.

Zweitens — und das ist der eigentliche Befund: Kein untersuchtes Verfahren schlägt die Baseline nachweisbar. Die Arbeit hatte vorab festgelegt, dass ein Verfahren nur dann erfolgreich ist, wenn es die Poisson-Baseline übertrifft. Das Ergebnis:

VERGLEICH	UNTERSCHIED IM RMSE	GEWONNENE WIEDERHOLUNGEN	P-WERT
Ridge gegen Baseline	+2,06 [−0,76 bis +4,88]	8 von 10	0,275
Random Forest gegen Baseline	−1,98 [−7,66 bis +3,71]	6 von 10	0,922
XGBoost gegen Baseline	−4,40 [−9,50 bis +0,69]	4 von 10	0,275
Ridge gegen Random Forest	+4,04 [+0,58 bis +7,49]	9 von 10	0,023
Ridge gegen XGBoost	+6,46 [+3,53 bis +9,40]	10 von 10	0,012
Random Forest gegen XGBoost	+2,43 [−0,79 bis +5,64]	7 von 10	0,211

Tabelle 10 der Arbeit. Ein Pluszeichen heißt: das erstgenannte Verfahren ist besser. In eckigen Klammern das *Konfidenzintervall*. Die p-Werte der unteren drei Zeilen sind für den Mehrfachvergleich nach Holm korrigiert. Fette p-Werte unter 0,05 sind statistisch absicherbar.

Man liest diese Tabelle so: In den oberen drei Zeilen enthält der Klammerbereich jedes Mal die Null — damit ist auch „gar kein Unterschied“ eine plausible Erklärung. Kein untersuchtes Verfahren hat die Baseline geschlagen. Aber — und das gehört zur Ehrlichkeit dazu — auch keines ist nachweisbar schlechter.

In den unteren drei Zeilen wird das Bild deutlich: **Ridge schlägt beide Baumverfahren**, gegen XGBoost in allen zehn Wiederholungen. Die drei untersuchten Verfahren unterscheiden sich also sehr wohl voneinander — nur eben nicht von der schlichten Baseline. Ausgerechnet das einfachste der drei liegt vorn.


WARUM SICH DIE RANGFOLGE AUF DEN SECHS STADTTEILEN UMDREHT

In der Kreuzvalidierung gewinnt Ridge, auf den sechs zurückgehaltenen Stadtteilen XGBoost. Die Arbeit erklärt diesen Widerspruch nicht weg, sondern ordnet ihn ein: Die beiden Auswertungen bilden keine gemeinsame Zahlenreihe. Links wird fünfzigmal nach Anpassung auf 24 Stadtteilen gemessen, rechts einmal an sechs Einheiten nach Anpassung auf 30 — ohne Streuung und ohne statistischen Test. Welches Verfahren vorn liegt, hängt bei rund 39 unabhängigen Einheiten davon ab, welche Stadtteile gerade im Test stehen und auf wie vielen angepasst wird. Dass die Rangfolge kippt, passt zu diesem Aufbau und begründet für sich genommen *keine* der beiden Reihenfolgen.

Ergebnis 2 · Die Art der Einsätze

Hier ist zuerst wichtig, was überhaupt erreichbar wäre. Die Arbeit misst das vor der Modellwahl und kommt auf zwei Obergrenzen (in der Arbeit „Decke A“ und „Decke B“). Die eine kommt daher, dass die Zielgröße selbst unscharf ist: Zieht man den Zufall neu, wechselt die überwiegende Einsatzart in 13,6 % der Stadtteil-Monate. Die andere kommt daher, dass sich die Merkmale innerhalb eines Stadtteils kaum bewegen — ein Modell kann im Kern nicht mehr tun, als jedem Stadtteil seine häufigste Art zuzuweisen, und 27 der 30 Stadtteile haben dieselbe.

KREUZVALIDIERUNG · MACRO-F1 (1,0 WÄRE FEHLERFREI)



SCHLUSSEBEWERTUNG · 6 ZURÜCKGEHALTENE STADTTTEILE



Abbildung 10: Obergrenze B beschreibt, was mit Merkmalen erreichbar ist, die sich innerhalb eines Stadtteils kaum ändern — eine Näherung von unten, weil Kriminalitätsindex und Saisonterme doch schwanken; Obergrenze A liegt darüber und ergibt sich aus der Unschärfe der Zielgröße selbst. Der gesamte Spielraum für Merkmals- und Verfahrenswahl liegt zwischen der Mehrheitsklasse und Obergrenze B — das sind 0,193 Macro-F1. Werte aus Tabelle 11 der Arbeit.

MODELL	KREUZVALIDIERUNG		SCHLUSSEBEWERTUNG	
	MACRO-F1	AUROC	MACRO-F1	AUROC
Mehrheitsklasse (Stufe 1)	0,221	—	0,222	—
Multinomiales Logit (Baseline)	0,301 ± 0,015	0,725	0,350	0,797
Random Forest	0,318 ± 0,014	0,705	0,282	0,762
XGBoost	0,301 ± 0,015	0,665	0,291	0,818
Obergrenze B	0,415	—	0,423	—
Obergrenze A	0,641	—	0,677	—

Tabelle 11 der Arbeit. Das ±-Zeichen gibt die Streuung über die zehn Wiederholungen an.

WAS DAS BEDEUTET

In der Kreuzvalidierung schlägt der Random Forest die Baseline — um 0,017 Macro-F1, in neun von zehn Wiederholungen, mit $p = 0,004$. Das ist der einzige Vergleich in der gesamten Arbeit, in dem ein untersuchtes Verfahren das vorab gesetzte Erfolgskriterium erfüllt. **XGBoost liegt mit $-0,0003$ praktisch auf dem Niveau der Baseline** ($p = 1,000$). Die Macro-AUROC spricht dagegen für die Baseline: Sie liegt mit 0,725 über beiden Baumverfahren (0,705 und 0,665).

Gemessen am Erreichbaren bleibt der Vorsprung allerdings klein: Der Random Forest schöpft 50,2 % des Abstands zwischen Mehrheitsklasse und Obergrenze B aus, XGBoost 41,0 %. Bis zur Obergrenze fehlen dem besseren noch 0,096 Macro-F1.

Auf den sechs zurückgehaltenen Stadtteilen kehrt sich auch das um: Dort liegt das schlichte Logit mit 0,350 vor beiden Baumverfahren (0,291 und 0,282). Die Arbeit nennt zwei mögliche Erklärungen — Über-

anpassung der Baumverfahren, oder die andere Klassenverteilung der zurückgehaltenen Stadtteile — und stellt ausdrücklich keine davon als entschieden dar.

EIN ERGEBNIS, DAS MAN KENNEN SOLLTE, BEVOR MAN DIESE ZAHLEN VERWENDET

Das Macro-F1 von 0,318 wird fast vollständig von den beiden häufigen Kategorien getragen. Der Random Forest erreicht im Einzelnen: 0,860 für Fehllalarm, 0,373 für technische Hilfe, **0,040 für Rettungseinsätze und 0,000 für Brände**. Die seltenste Kategorie sagt er in 49 von 50 Läufen kein einziges Mal vorher. XGBoost ver- gibt sie zwar häufiger (in 2.178 von 39.590 Testzeilen), trifft sie aber nur elfmal (F1 von 0,005).

Ein Viertel des Leitmaßes ruht damit auf einer Kategorie, die keines der beiden Baumverfahren erkennt — ausgerechnet auf den Bränden. Die Arbeit schreibt das so hin, ohne es zu beschönigen.

Ergebnis 3 · Der Rechenaufwand

Hier trennen sich die Verfahren eindeutig, und als einziges Ergebnis der Arbeit nicht um Prozentpunkte, sondern um Größenordnungen.

TRAININGSZEIT FÜR EINEN DURCHLAUF (EINSATZHÄUFIGKEIT)




Abbildung 11: Werte aus Tabelle 13 der Arbeit. Wichtig: Die Arbeit weist darauf hin, dass alle Zeiten aus einem einzigen Durchgang stammen und jede Anpassung nur zweimal gemessen ist — die Zahlen sind als Größenordnung zu lesen, nicht als exakte Kennzahl. Und im Alltag wäre selbst das langsamste Verfahren schnell genug: Es sagt eine komplette Prüfgruppe in unter einer Zehntelsekunde vorher.

Der größte Posten ist ohnehin nicht das Training selbst, sondern die Suche nach den richtigen Einstellungen davor: 25 Suchläufe mit je 100 Versuchen über vier innere Prüfgruppen ergeben 10.000 Modellanpassungen und rund 137 Minuten reine Suchzeit — davon 36 Sekunden auf Ridge. Der Aufwandsnachteil der Baumverfahren entsteht also nicht erst beim fertigen Modell, sondern vervielfacht sich über die Modellwahl.

Die Gegenprobe: eine flexiblere Baseline

Die Arbeit macht eine Gegenprobe, die das Gesamtbild erst richtig zusammensetzt. Sie prüft, ob die Baseline vielleicht einfach zu starr ist. Dafür wird nicht das *Verfahren* gewechselt, sondern die Baseline selbst schrittweise flexibler *angesetzt*. Wäre sie zu starr, müsste sie mit jeder Erweiterung besser werden.

RMSE — DIESELBE AUFGABE, VERSCHIEDENE ANSÄTZE



Die Wahl des **Verfahrens** ändert den Fehler um höchstens **4,4**.
Die Wahl der **Ansatzform** ändert ihn um bis zu **4.170,3** — fast das Tausendfache.

Abbildung 12: Werte aus Abschnitt 6.3 und Tabelle 9 der Arbeit, auf eine Nachkommastelle gerundet. Wäre die Baseline zu starr, müsste sie durch mehr Flexibilität besser werden. Das Gegenteil tritt ein — und zwar dramatisch. Geprüft sind nur Erweiterungen ohne Strafterm. Die vier obersten Balken sind bei diesem Maßstab kaum noch sichtbar; genau das ist die Aussage.

Der Vergleich ist auf zwei Arten lehrreich. Erstens spricht er gegen die Vermutung, die Baseline sei schlicht zu starr: Erweiterungen ohne Strafterm machen sie hier massiv schlechter, nicht besser — obwohl die Arbeit an anderer Stelle nachweist, dass der lineare Ansatz die Übungsdaten nicht ganz trifft. Zweitens rückt er die Verfahrensfrage zurecht: Die Ansatzform bewegt den Fehler um ein Vielfaches stärker als der Tausch des Verfahrens. Die Arbeit beziffert das so: Zwischen den Verfahren liegen höchstens 6,46 RMSE, zwischen den Ansatzformen bis zu 4.170,28. Der erste Abstand ist damit nicht einmal zwei Promille des zweiten **ZUSATZ**.

Welche Merkmale zählen

Zum Schluss noch der inhaltliche Befund — und er enthält eine Überraschung. Die Arbeit stellt zwei Fragen getrennt: Worauf *achtet* ein Modell (*Attribution*)? Und was *fehlt*, wenn man eine Gruppe wegnimmt (*Ablation*)?

MERKMALSGRUPPE	AUFMERKSAMKEIT DES MODELLS	FEHLERÄNDERUNG BEIM WEGLASSEN	WIE OFT SCHLECHTER
kriminallitätsbezogen	10,7 %	+6,10 deutlich schlechter	10 von 10
sozioökonomisch	41,4 %	−4,95 besser	1 von 10
baulich	34,0 %	−8,04 besser	0 von 10
Größenkontrolle	8,9 %	−5,02 besser	0 von 10
Saison	5,1 %	+0,28	10 von 10

Abbildung 6 und Tabelle 14 der Arbeit, Mengenstrang, Poisson-GLM. Die Aufmerksamkeit ist der Anteil der Gruppe an der Summe der Beträge aller standardisierten Koeffizienten, berechnet auf einer einzigen Prüfgruppe (der fünften der ersten Wiederholung); die Fehleränderung ist über die zehn Wiederholungen gemittelt. Ein Plus bei der Fehleränderung heißt: Ohne diese Gruppe wird die Vorhersage schlechter — die Gruppe wird also gebraucht. Die letzte Spalte zählt, in wie vielen der zehn Wiederholungen das der Fall ist.

Die beiden Spalten stehen quer zueinander, und das ist der Punkt. Die kriminallitätsbezogene Gruppe besteht aus einem einzigen Merkmal und bekommt unter den drei inhaltlichen Gruppen die *geringste* Aufmerksamkeit — aber ohne sie wird die Vorhersage in allen zehn Wiederholungen deutlich schlechter. Umgekehrt bin-

den die sozioökonomischen und baulichen Merkmale drei Viertel der Aufmerksamkeit, und die Vorhersage wird im Mittel *besser*, wenn man sie weglässt.

Die Arbeit nennt drei am Datensatz messbare Eigenschaften, die das erklären können. Erstens die zeitliche Auflösung: Der Kriminalitätsindex ist das einzige Strukturmerkmal, das sich *von Monat zu Monat bewegt* — er nimmt je Stadtteil im Schnitt 128,1 verschiedene Werte an. Die sozioökonomischen Merkmale haben höchstens vier Werte über elf Jahre, die baulichen genau einen; sie sind faktisch Konstanten je Stadtteil. Zweitens die Überschneidung: Der Index hängt deutlich mit Risikogewerbeanteil, Leerstands- und Armutsquote zusammen (Korrelation 0,78, 0,63 und 0,57) und bündelt so deren Information. Neben ihm sind diese Merkmale also weitgehend doppelt, und bei nur 24 Trainingsstadtteilen kosten solche redundanten Merkmale mehr an Streuung, als sie an Verzerrung abbauen. Drittens der Offset: Das Poisson-Modell führt die Einwohnerzahl ohnehin mit, die Größenkontrolle ist dort doppelt. Ob der Vorrang des Index an seinem Inhalt liegt oder an seiner zeitlichen Auflösung, lässt die Arbeit offen.

WAS DIESER BEFUND AUSDRÜCKLICH NICHT HEISST

Die Arbeit formuliert das selbst sehr vorsichtig, und das gehört hierher: Belegt ist nicht, dass Kriminalität Feuerwehreinsätze *verursacht*. Die Spalte stammt aus polizeilichen Meldungen und ist deshalb kein reines Maß des Tatgeschehens: Sie hängt auch an der Anzeigebereitschaft und an der Kontrollintensität der Polizei. Belegt ist nur, dass die Vorhersage der Einsatzzahl ohne die registrierte Kriminalitätsbelastung schlechter wird als ohne jede andere Merkmalsgruppe. Die gesamte Arbeit ist prognoseorientiert und erhebt keinen Ursachenanspruch.

Die Antwort in drei Punkten

1. Ja, es funktioniert — im Grundsatz. Aus den Merkmalen eines Stadtteils lässt sich seine Einsatzlast vorher-sagen, auch für einen Stadtteil, den das Modell nie gesehen hat. Der Fehler liegt bei rund 20 Einsätzen im Mittel und damit weit unter dem, was ein Durchschnittswert leisten würde.

2. Aber die aufwendigen Verfahren sind kaum besser als die schlichten. Bei der Frage nach der Anzahl schlägt keines der drei untersuchten Verfahren die schlichte Baseline nachweisbar; bei der Frage nach der Art gelingt es einzig dem Random Forest, und nur in einer der beiden Auswertungen. Dabei braucht XGBoost je Anpassung das 295-Fache der Trainingszeit von Ridge, der Random Forest das 326-Fache.

3. Und: Die Verfahrenswahl ist gar nicht der entscheidende Hebel. Zwischen den Verfahren liegen höchstens 6,46 RMSE-Punkte. Schon das Weglassen der baulichen Merkmale senkt den Fehler der Baseline um 8,04, und zwischen Ansatzformen ohne Strafterm liegen bis zu rund 4.170. Aus ihrem Gesamtbefund leitet die Arbeit eine übertragbare Regel für ähnliche Aufgaben ab: Dass ein linearer Ansatz den Daten nachweislich nicht ganz gerecht wird, begründet für sich genommen noch kein aufwendigeres Verfahren — solange die Prüfung Tausende voneinander abhängiger Zeilen behandelt, als wären sie unabhängig. Über die Verfahrenswahl entscheiden wenige Dutzend wirklich unabhängige Einheiten, und an ihnen lässt sich hier bei der Einsatzzahl kein aufwendigeres Verfahren von der schlichten Baseline trennen. Die Arbeit rät deshalb, zuerst zu prüfen, wie viele solcher Einheiten die Daten enthalten und für wie viele Merkmale sie reichen — und erst danach das Verfahren zu wählen.

Was diese Zusammenfassung nicht behauptet

Die folgenden Punkte werden hier ausdrücklich als offen gekennzeichnet, weil die Arbeit sie selbst nicht abschließend entscheidet. **Welche der beiden Auswertungen die „richtige“ ist** — nur die Kreuzvalidierung erlaubt einen statistischen Test, eine feste Rangfolge der Verfahren leitet die Arbeit aber aus keiner der beiden ab. **Warum genau sich die Rangfolgen umkehren** — die Arbeit nennt für die Einsatzart zwei mögliche Erklärungen und lässt beide nebeneinander stehen. **Ob die Ergebnisse auf andere Städte übertragbar sind** — die Arbeit nennt dafür zwei vermutliche Voraussetzungen (ein monatlich fortgeschriebenes Merkmal und eine vergleichbare polizeiliche Meldepraxis) und prüft die Übertragung nicht. Die **Aufmerksamkeitsanteile** in der letzten Tabelle stammen aus dem Poisson-Modell des Mengenstrangs; für die Einsatzart gelten andere Werte, und die Arbeit weist darauf hin, dass sich die beiden Baumverfahren darin nicht direkt vergleichen lassen.

Grundlage dieser Zusammenfassung: Bachelorarbeit „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und sozioökonomischer Merkmale – ein Vergleich ausgewählter Machine-Learning-Methoden am Beispiel von Stadtteildaten“ (Fassung vom 5. Oktober 2026), insbesondere die Kapitel 1 bis 8, die Tabellen 3, 5, 6 und 9 bis 14 sowie die Abbildungen 1 und 4 bis 6. Alle Zahlenwerte wurden gegen diese Fassung abgeglichen. Sachangaben, die nicht in der Arbeit stehen, sind mit **ZUSATZ** markiert; Bilder und Vergleiche wie Mischpult oder Publikumsjoker sind Erklärhilfen dieser Zusammenfassung. Die Abbildungen dieser Zusammenfassung wurden eigens dafür gezeichnet und sind keine Reproduktionen der Originalabbildungen; wo sie Beispielwerte zeigen, ist das in der Bildunterschrift vermerkt.